

The background image shows the main entrance gate of Jiaotong University. The gate is a large, white, curved structure with the university's name in English, "JIAOTONG UNIVERSITY", on the right side and in Chinese, "交通大学", on the left. To the left of the gate is a large, brown, textured wall with a relief sculpture. In the background, there are green trees and a building with a red roof. A dark purple banner with yellow text is overlaid on the image.

## 1-1 问题模型与基本概念

## 问题实例1：线性规划

**问题描述** 某公司生产甲乙两种商品，每件甲商品要耗A种原料3kg, B种原料3kg, 产值为180元; 每件乙商品要耗A种原料4.5kg, B种原料1.5kg, 产值为150元. 现公司共有A种原料900kg, B种原料600kg, 试确定甲乙两种商品共生产多少件, 使得公司的总产值最大.

**建模分析:**

**变量:** 生产甲商品 $x_1$ 件, 乙商品 $x_2$ 件, 故公司总产值为

$$180x_1 + 150x_2 (\text{目标函数})$$

## 问题实例1：线性规划

约束： 考虑到A,B两种原材料总量限制, 故 $x_1, x_2$ 需满足如下不等式约束条件:

$$\begin{cases} 3x_1 + 4.5x_2 \leq 900 \\ 3x_1 + 1.5x_2 \leq 600 \end{cases}$$

非负约束:  $x_1 \geq 0, x_2 \geq 0$ .

---

线性规划模型:


$$\begin{aligned} \max \quad & z = 180x_1 + 150x_2 \\ \text{s.t.} \quad & 3x_1 + 4.5x_2 \leq 900 \\ & 3x_1 + 1.5x_2 \leq 600 \\ & x_1 \geq 0, x_2 \geq 0 \end{aligned}$$

## 问题实例2：非线性规划

问题模型:


$$\begin{aligned} \min_{x_1, x_2} \quad & (x_1 - 2)^2 + (x_2 - 2)^2 \\ \text{s.t.} \quad & x_1 + 2x_2 = 4 \\ & x_1 \geq 0, x_2 \geq 0 \end{aligned}$$

求解分析：可行域 $\Omega = \{(x_1, x_2) | x_1 + 2x_2 = 4, x_1 \geq 0, x_2 \geq 0\}$



## 实例问题3：感知机二分类问题

感知机（1957年）是较早的二分类的线性分类模型，也是后来神经网络和支持向量机的基础。感知机的目标为确定一个超平面 $\boldsymbol{w}^T \boldsymbol{x} + b = 0$ ，使得将训练集中的正类点和负类点分开。



感知机的分类模型如下：

$$f(\boldsymbol{x}) = \text{sign}(\boldsymbol{w}^T \boldsymbol{x} + b) = \begin{cases} 1 & \boldsymbol{w}^T \boldsymbol{x} + b \geq 0 \\ -1 & \text{otherwise} \end{cases}$$

## 实例问题3：感知机二分类问题

为确定分类模型中参数 $\mathbf{w}, b$ , 考虑极小化误分类样本点到超平面的距离, 即

$$-\frac{1}{\|\mathbf{w}\|} \sum_{i=1}^N y_i (\mathbf{w}^T \mathbf{x}_i + b)$$

其中 $(\mathbf{x}_i, y_i), i = 1, \dots, N$ , 为样本点与相应分类结果对。这里,  $y_i = 1$ 或者 $y_i = -1$ 。

注意成倍增加 $(\mathbf{w}, b)$ 不改变超平面, 故感知机只需极小化如下损失函数:

$$\text{minimize } L(\mathbf{w}, b) = - \sum_{i=1}^N y_i (\mathbf{w}^T \mathbf{x}_i + b)$$

## 问题4：投资规划问题

假定一个投资方案里有 $n$ 个投资项目, 项目 $i$ 的回报率为:

$$r_i, \quad i = 1, 2, \dots, n$$

单个投资项目 $i$ 的通常假定满足正态分布的随机变量, 其均值和方差表分别表示如下:

$$\mu_i = E[r_i](\text{收益}) \quad \sigma_i^2 = E[(r_i - \mu_i)^2](\text{风险})$$

假定投资在项目 $i$ 上的资金比为:  $x_i, i = 1, \dots, n$ , 则投资方案的利润回报与期望回报分别为:

$$R = \sum_{i=1}^n x_i r_i. \quad E[R] = E\left[\sum_{i=1}^n x_i r_i\right] = \sum_{i=1}^n x_i E[r_i] = \mathbf{x}^T \boldsymbol{\mu}$$

## 问题4：投资规划问题

整个投资的方差由下式给出：

$$E[(R - E(R))^2] = \sum_{i=1}^n \sum_{j=1}^n x_i x_j \sigma_i \sigma_j \rho_{ij} = \mathbf{x}^T G \mathbf{x},$$

其中项目回报协方差为： $\rho_{ij} = \frac{E[(r_i - \mu_i)(r_j - \mu_j)]}{\sigma_i \sigma_j}$ ,  $i, j = 1, 2, \dots, n$ . 矩阵  $G_{n \times n}$  定义为： $G_{ij} = \rho_{ij} \sigma_i \sigma_j$ . 可以证明  $G$  是半正定的。

最优组合投资 **Markowitz模型**：

$$\begin{aligned} \max \quad & \mathbf{x}^T \boldsymbol{\mu} - \kappa \mathbf{x}^T G \mathbf{x} \\ \text{s.t.} \quad & \sum_{i=1}^n x_i = 1, \mathbf{x} \geq 0, \end{aligned}$$

这里风险允许参数  $\kappa \in [0, \infty)$ ，依赖于投资者的偏好。




# 最优化问题数学模型

一般优化问题**数学模型**可表述为:

$$\begin{array}{ll}\min & f(\boldsymbol{x}) \\ \text{s.t.} & c_i(\boldsymbol{x}) = 0, i \in \mathcal{E}; c_j(\boldsymbol{x}) \geq 0, j \in \mathcal{I}\end{array}$$

其中:

- **决策变量** -  $\boldsymbol{x} = (x_1, x_2, \dots, x_n)^T \in R^n$ ;
- **目标函数** -  $f: R^n \rightarrow R$ ;
- **约束函数** -  $c_i: R^n \rightarrow R, i \in \mathcal{E} \cup \mathcal{I}$ .  
 $\mathcal{E} = \{1, \dots, m_e\}; \mathcal{I} = \{m_e + 1, \dots, m\}$
- **可行域**:  $\Omega = \{\boldsymbol{x} | c_i(\boldsymbol{x}) = 0, i \in \mathcal{E}; c_j(\boldsymbol{x}) \geq 0, j \in \mathcal{I}\}$



缩写min 对应minimize (极小化) s.t. 对应subject to (受约束)

# 问题转换

- 极大极小类型转换:

$$\max f(\mathbf{x}) \leftrightarrow \min -f(\mathbf{x})$$

- 约束类型转换:

- 不等式符号转换:

$$c_i(\mathbf{x}) \leq 0 \leftrightarrow -c_i(\mathbf{x}) \geq 0$$

- 一般形式转换标准形式:

$$a(\mathbf{x}) \leq b(\mathbf{x}) + c \leftrightarrow h(\mathbf{x}) = b(\mathbf{x}) - a(\mathbf{x}) + c \geq 0$$

# 优化问题分类

- 连续性与光滑性：

- 连续与离散(组合优化)、光滑与非光滑

- 约束条件：

- 无约束优化与约束优化

- 目标与约束的线性性：

- 线性规划与非线性规划

- 变量随机性：

- 确定性优化与不确定性优化(随机优化)

- 优化目标数量：

- 单目标优化与多目标优化

# 约束优化问题

- 等式约束优化问题(equality constraint):

$$\begin{cases} \min & f(\mathbf{x}), \\ \text{s.t.} & c_i(\mathbf{x}) = 0, \quad i = 1, 2, \dots, m_e. (m = m_e) \end{cases}$$

- 不等约束优化问题(inequality constraint):


$$\begin{cases} \min & f(\mathbf{x}), \\ \text{s.t.} & c_i(\mathbf{x}) \geq 0, \quad i = 1, 2, \dots, m. (m_e = 0) \end{cases}$$

- 混合约束优化问题 既有等式约束，又有不等式约束。

**注意：** 约束优化问题经常转化为无约束优化问题来求解。

# 约束优化可行域

定义1.1.1: 若点 $\boldsymbol{x} \in R^n$ 满足优化问题模型中所有约束条件, 则称 $\boldsymbol{x}$ 为可行点 (Feasible Point)。可行点的全体称为可行域(Feasible Region)。



例子: 可行域 $\Omega = \{\boldsymbol{x} \in R^3 | c_1(\boldsymbol{x}) = 2x_1 + 3x_2 + x_3 - 6 = 0, x_i \geq 0, i = 1, 2, 3\}$ 的边界由粗线表示。

# 特殊优化问题：线性规划

线性规划(Linear Programming)数学模型：

$$\begin{array}{ll}\min & \mathbf{c}^T \mathbf{x}, \\ \text{s.t.} & A_1 \mathbf{x} = \mathbf{b}_1, A_2 \mathbf{x} \geq \mathbf{b}_2,\end{array}$$

其中：

- $\mathbf{c} = (c_1, c_2, \dots, c_n)^T$ ,  $\mathbf{b}_1 = (b_1, b_2, \dots, b_m)^T$ ,  $\mathbf{b}_2 = (b_{m+1}, \dots, b_p)^T$ ,
- 约束矩阵：

$$A_1 = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \cdots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}, A_2 = \begin{bmatrix} a_{m+1,1} & a_{m+1,2} & \cdots & a_{m+1,n} \\ \vdots & \vdots & \cdots & \vdots \\ a_{p1} & a_{p2} & \cdots & a_{pn} \end{bmatrix}.$$

# 特殊优化问题：二次规划

二次规划(Quadratic Programming)数学模型:

$$\begin{array}{ll}\min & q(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T G \mathbf{x} + \mathbf{c}^T \mathbf{x} + d, \\ \text{s.t.} & A_1 \mathbf{x} = \mathbf{b}_1; A_2 \mathbf{x} \geq \mathbf{b}_2\end{array}$$

其中:  $A_1, A_2, \mathbf{b}_1, \mathbf{b}_2$  的表示与线性规划模型类似,  $\mathbf{c} = (c_1, c_2, \dots, c_n)^T$ ,  $d$  为标量,  $G$  为  $n \times n$  阶对称矩阵:


$$G = \begin{bmatrix} G_{11} & G_{12} & \cdots & G_{1n} \\ G_{21} & G_{22} & \cdots & G_{2n} \\ \vdots & \vdots & \cdots & \vdots \\ G_{n1} & G_{n2} & \cdots & G_{nn} \end{bmatrix},$$

满足  $G_{ij} = G_{ji}, \forall i \neq j$ .

# 全局最优和局部最优

定义1.1.2: 对于任意 $\mathbf{x} \in \Omega$ , 若可行点 $\mathbf{x}^* \in \Omega$ 满足 $f(\mathbf{x}^*) \leq f(\mathbf{x})$ , 则称 $\mathbf{x}^*$ 为最优化问题的**全局最优解**(或**全局极小点**)。若对于任意 $\mathbf{x} \in \Omega$ 且 $\mathbf{x} \neq \mathbf{x}^*$ , 有 $f(\mathbf{x}^*) < f(\mathbf{x})$ , 则称 $\mathbf{x}^*$ 为**严格全局最优解**(或**严格全局极小点**)。


定义1.1.3: 若可行点 $\mathbf{x}^*$ 的邻域为 $\mathcal{N}(\mathbf{x}^*) = \{\mathbf{x} \mid \|\mathbf{x} - \mathbf{x}^*\| \leq \delta\}$ 。若任意 $\mathbf{x} \in \mathcal{N}(\mathbf{x}^*) \cap \Omega$ , 满足 $f(\mathbf{x}^*) \leq f(\mathbf{x})$ , 则称 $\mathbf{x}^*$ 为最优化问题的**局部最优解**(或**局部极小点**)。若对于任意 $\mathbf{x} \in \mathcal{N}(\mathbf{x}^*) \cap \Omega$ 且 $\mathbf{x} \neq \mathbf{x}^*$ , 有 $f(\mathbf{x}^*) < f(\mathbf{x})$ , 则称 $\mathbf{x}^*$ 为**严格局部最优解**(**严格局部极小点**)。





# 函数图形与等高线

欲求函数的极小值，通过函数图形可直观地了解函数的特性。对于二维问题，所谓等高线就是函数值取常数值的所有点的集合，即 $f(\boldsymbol{x}) = c$ 。常数值 $c$ 取不同值对应一族曲线。



若目标函数为连续的单值函数，则具有以下性质：(i) 不同等值线不相交；(2) 除极值点外，等值线不会中断；(3) 等值线稠密(稀疏)的地方，函数值变化较快(慢)；(4) 极值点附近，等值线近似地呈现同心椭圆族。

# 梯度与海森矩阵

在研究最优性条件与优化算法时, 通常假定目标函数或者约束函数的导数存在, 比如:

- 一阶梯度向量:

$$\mathbf{g}(\mathbf{x}) = \nabla f(\mathbf{x}) = \left[ \frac{\partial f(\mathbf{x})}{\partial x_1}, \frac{\partial f(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial f(\mathbf{x})}{\partial x_n} \right]$$

- 二阶海森矩阵:

$$G(\mathbf{x}) = \nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f(\mathbf{x})}{\partial x_1^2} & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_2^2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_1} & \frac{\partial^2 f(\mathbf{x})}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f(\mathbf{x})}{\partial x_n^2} \end{bmatrix}$$

在最优解 $\mathbf{x}^*$ 处, 通常使用以下记号表示 $\mathbf{x}^*$ 的函数值/梯度/海森矩阵:

$$f^* = f(\mathbf{x}^*), \mathbf{g}^* = \mathbf{g}(\mathbf{x}^*), G^* = G(\mathbf{x}^*).$$

# 梯度与海森矩阵

## 梯度的性质：

- 若  $\nabla f(\mathbf{x}) \neq 0$ , 则  $\nabla f(\mathbf{x})$  必与过  $\mathbf{x}$  点的等值线垂直;
- 沿梯度方向函数具有最大的变化率。

## 海森矩阵的性质：

- 海森矩阵可描述函数的局部曲率;
- 海森矩阵具有对称性;
- 海森矩阵的正定性可用于判断函数的极值;
- 函数二阶近似中需用到海森矩阵。

# 一阶方向导数

定义1.1.4: 对 $\forall \mathbf{d} \in R^n \setminus \{\mathbf{0}\}$ (非零方向向量), 若极限:

$$\lim_{\alpha \rightarrow 0^+} \frac{f(\mathbf{x} + \alpha \mathbf{d}) - f(\mathbf{x})}{\alpha \|\mathbf{d}\|}$$

存在, 则称该极限为函数 $f$ 在 $\mathbf{x}$ 处沿着方向 $\mathbf{d}$ 的方向导数, 记为:  $\frac{\partial f(\mathbf{x})}{\partial \mathbf{d}}$ 。  
方向导数是 $f(\mathbf{x})$ 在点 $\mathbf{x}$ 处沿着 $\mathbf{d}$ 的函数值变化率。

利用一阶方向导数( $f \in C^1$ )可以定义二阶方向导数( $f \in C^2$ ), 二者具体计算公式如下:

$$\begin{aligned}\frac{\partial f(\mathbf{x})}{\partial \mathbf{d}} &= \frac{1}{\|\mathbf{d}\|} g(\mathbf{x})^T \mathbf{d} \\ \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{d}^2} &= \frac{1}{\|\mathbf{d}\|^2} \mathbf{d}^T G(\mathbf{x})^T \mathbf{d}\end{aligned}$$