

The background of the slide is a faded photograph of the main entrance gate of Jiaotong University. The gate is a large, white, curved structure with the university's name in English, "JIAOTONG UNIVERSITY", on the right side and in Chinese, "交通大学", on the left. To the left of the gate is a large, brown stone relief sculpture. In the background, there are green trees and a multi-story building with a red roof. A dark purple horizontal bar is overlaid on the middle of the image, containing the section title in yellow text.

4-3 共轭梯度法

共轭梯度法

共轭梯度法最早是由Hestenes和Stiefel(1952)提出来的, 用于解正定系数矩阵的线性方程组. 在此基础上, Fletcher和Reeves(1964)首先提出了解非线性最优化问题的共轭梯度法。

共轭梯度法是介于最速下降法与牛顿法之间的一种优化方法, 其主要利用函数的一阶导数信息建立起来的方法, 对于正定二次函数具有二次终止性。

共轭梯度法在每步迭代中所需的计算量和存储量比Newton法少, 不仅是解大型线性方程组最有用的方法之一, 也是解大型非线性最优化问题最有效的算法之一。


特殊正定二次函数

针对正定二次函数：

$$\tilde{f}(\tilde{\mathbf{x}}) = \frac{1}{2} \tilde{\mathbf{x}}^T G \tilde{\mathbf{x}} + \mathbf{b}^T \tilde{\mathbf{x}} \quad (4.3.1)$$

其中 G 为 $n \times n$ 的**对角阵**, 对角元素为正。


考虑 $n = 3$ 情形, 从某初始点 $\tilde{\mathbf{x}}_0$ 出发, 分别沿着平行与坐标轴的方向 $\mathbf{e}_0, \mathbf{e}_1, \mathbf{e}_2$ 做精确线性搜索, 得到迭代点列 $\tilde{\mathbf{x}}_1, \tilde{\mathbf{x}}_2, \tilde{\mathbf{x}}_3$ 。经过3步迭代可精确找到正定二次函数的极小点。



一般正定二次函数

对于一般的正定二次函数 $f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T G \mathbf{x} + \mathbf{b}^T \mathbf{x}$ ，即 G 为对称正定矩阵，从任意点出发，沿 $\mathbf{e}_0, \mathbf{e}_1, \mathbf{e}_2$ 做精确线性搜索，显然不能期望得到极小点。

欲保持二次终止性，沿着 $\mathbf{d}_0, \mathbf{d}_1, \mathbf{d}_2$ 方向分别进行精确线性搜索。这些方向如何构造？



一般正定二次函数

考虑变换:

$$\mathbf{x} = D\tilde{\mathbf{x}}$$

这里

$$D = [\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}]_{n \times n}$$

关于 $\tilde{\mathbf{x}}$ 的函数形式为:

$$\tilde{f}(\tilde{\mathbf{x}}) = f(D\tilde{\mathbf{x}}) = \frac{1}{2}(D\tilde{\mathbf{x}})^T G(D\tilde{\mathbf{x}}) + \mathbf{b}^T(D\tilde{\mathbf{x}}) = \frac{1}{2}\tilde{\mathbf{x}}^T(D^T G D)\tilde{\mathbf{x}} + \mathbf{b}^T(D\tilde{\mathbf{x}})$$

若对 $i \neq j$, 有:

$$\mathbf{d}_i^T G \mathbf{d}_j = 0$$

成立, 则以上函数的海森矩阵 $D^T G D$ 为对角阵。

定义4.3.1: 设 G 是 $n \times n$ 对称正定矩阵, $\mathbf{d}', \mathbf{d}''$ 是 n 维非零向量。如果

$$\mathbf{d}'^T G \mathbf{d}'' = 0, \quad (4.3.2)$$

则称向量 \mathbf{d}' 和 \mathbf{d}'' 是关于矩阵 G 共轭的(G -共轭或 G -正交)。

设 $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$ 是 \mathbb{R}^n 中一组非零向量,如果

$$\mathbf{d}_i^T G \mathbf{d}_j = 0, \quad (i, j = 0, \dots, n-1, i \neq j) \quad (4.3.3)$$

则称向量组 $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$ 是关于矩阵 G 共轭的。

可以证明: 若向量组 $\mathbf{d}_0, \mathbf{d}_1, \dots, \mathbf{d}_{n-1}$ 是 G -共轭的,则它们是线性无关的。特别地取 G 为单位阵, 则共轭性即为通常的正交性。

变换矩阵

变换矩阵 D 可以取为正定矩阵平方根逆矩阵。 G 的平方根矩阵定义与性质如下。

定义4.3.2 设 G 为 $n \times n$ 对称正定矩阵. 若存在对称正定矩阵 T , 使得 $T^2 = G$, 则称 T 为 G 的**平方根矩阵**, 记为: $T = \sqrt{G}$ 或 $T = G^{\frac{1}{2}}$ 。

定理4.3.1 平方根矩阵的存在唯一性.

若 G 是 $n \times n$ 对称正定矩阵, 则 G 的平方根矩阵存在且唯一。

取 $D^{-1} = \sqrt{G}$, 则有: $\mathbf{e}_i^T \mathbf{e}_j = (\sqrt{G} \mathbf{d}_i)^T (\sqrt{G} \mathbf{d}_j) = \mathbf{d}_i^T G \mathbf{d}_j = 0$ 。对于 $\tilde{f}(\tilde{\mathbf{x}})$ 沿着 $\mathbf{e}_0, \dots, \mathbf{e}_{n-1}$ 方向依次进行迭代, 通过变换 $\mathbf{x} = D\tilde{\mathbf{x}}$, 就成为 $f(\mathbf{x})$ 沿着 $\mathbf{d}_0, \dots, \mathbf{d}_{n-1}$ 方向依次进行迭代。

一般共轭方向法步骤

算法4.3.1 一般共轭方向法

步1 给出初始点 $\mathbf{x}_0, \epsilon > 0, k := 0$. 计算 $\mathbf{g}_0 = \mathbf{g}(\mathbf{x}_0)$ 和初始下降方向 \mathbf{d}_0 , 使 $\mathbf{d}_0^T \mathbf{g}_0 < 0$.

步2 如果 $\|\mathbf{g}_k\| \leq \epsilon$, 停止迭代。

步3 计算 α_k 和 \mathbf{x}_{k+1} , 使得

$$\begin{aligned} f(\mathbf{x}_k + \alpha_k \mathbf{d}_k) &= \min_{\alpha \geq 0} f(\mathbf{x}_k + \alpha \mathbf{d}_k), \\ \mathbf{x}_{k+1} &= \mathbf{x}_k + \alpha_k \mathbf{d}_k. \end{aligned}$$

步4 采用某种共轭方向法计算 \mathbf{d}_{k+1} 使得

$$\mathbf{d}_{k+1}^T \mathbf{G} \mathbf{d}_j = 0, j = 0, 1, \dots, k.$$

步5 令 $k := k + 1$, 转步2.

共轭方向法

极小化正定二次函数:

$$\min_{\mathbf{x}} f(\mathbf{x}) = \frac{1}{2} \mathbf{x}^T G \mathbf{x} - \mathbf{b}^T \mathbf{x}, \quad (4.3.4)$$

由一阶最优性必要条件, 以上问题等价于解线性方程组:

$$G \mathbf{x} = \mathbf{b}, \quad (4.3.5)$$

记: $\mathbf{r}(\mathbf{x}) \triangleq G \mathbf{x} - \mathbf{b} = \mathbf{g}(\mathbf{x})$ (4.3.5) 的残量等于目标函数梯度。

共轭方向法的迭代格式: $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k$. 由精确线性搜索确定步长因子为:

$$\alpha_k = -\frac{\mathbf{g}_k^T \mathbf{d}_k}{\mathbf{d}_k^T G \mathbf{d}_k}, \quad (4.3.6)$$

其中: $\mathbf{g}_k = G \mathbf{x}_k - \mathbf{b} \triangleq \mathbf{r}_k$.

共轭方向

定理4.3.1 共轭方向基本定理.

设 $\mathbf{x}_0 \in \mathbb{R}^n$ 是任意初始点。对于极小化二次函数(4.3.4), 共轭方向法至多经 n 步精确线性搜索终止;且每一迭代点 \mathbf{x}_{k+1} 都是 $f(\mathbf{x})$ 在 \mathbf{x}_0 和方向 $\mathbf{d}_0, \dots, \mathbf{d}_k$ 所张成的线性流形

$$\left\{ \mathbf{x} \mid \mathbf{x} = \mathbf{x}_0 + \sum_{j=0}^k \beta_j \mathbf{d}_j, \forall \beta_j \right\}$$

中的极小点。

该定理表明：在精确线性搜索条件下,共轭方向法具有二次终止性(即对于正定二次函数,方法是有限步终止的)。

定理4.3.1证明

证明： 因 G 正定,且向量组

$$\mathbf{d}_0, \mathbf{d}_1, \cdots$$

线性无关, 故只需要证明对所有的 $k \leq n-1$,有

$$\mathbf{g}_{k+1}^T \mathbf{d}_j = 0, \quad j = 0, \cdots, k, \quad (4.3.7)$$

便可得出定理结论。

由于

$$\mathbf{g}_{i+1} - \mathbf{g}_i = G(\mathbf{x}_{i+1} - \mathbf{x}_i) = \alpha_i G \mathbf{d}_i \quad (4.3.8)$$

结合在精确线性搜索得：

$$\mathbf{g}_{i+1}^T \mathbf{d}_i = 0, \quad (4.3.9)$$

定理4.3.1证明续

证明续: 故有当 $j < k$ 时,

$$\begin{aligned} \mathbf{g}_{k+1}^T \mathbf{d}_j &= \mathbf{g}_{j+1}^T \mathbf{d}_j + \sum_{i=j+1}^k (\mathbf{g}_{i+1} - \mathbf{g}_i)^T \mathbf{d}_j \\ &= \mathbf{g}_{j+1}^T \mathbf{d}_j + \sum_{i=j+1}^k \alpha_i \mathbf{d}_i^T G \mathbf{d}_j = 0. \end{aligned} \quad (4.3.10)$$

在上式中两项为零分别由精确线性搜索和共轭性得到。

当 $j = k$ 时,直接由精确线性搜索可知

$$\mathbf{g}_{k+1}^T \mathbf{d}_k = 0. \quad (4.3.11)$$

从而(4.3.7)成立。

定理4.3.1证明续

证明续: 对 \mathbf{x}_k 与任意给定线性流形中的 \mathbf{x} , 有:

$$\mathbf{x}_k = \mathbf{x}_0 + \sum_{j=1}^{k-1} \alpha_j \mathbf{d}_j, \quad \mathbf{x} = \mathbf{x}_0 + \sum_{j=1}^{k-1} \beta_j \mathbf{d}_j,$$

由 G 的正定性与(4.3.7)式, 有:

$$\begin{aligned} f(\mathbf{x}) &= f(\mathbf{x}_k) + (\mathbf{x} - \mathbf{x}_k)^T \mathbf{g}_k + \frac{1}{2}(\mathbf{x} - \mathbf{x}_k)^T G(\mathbf{x} - \mathbf{x}_k) \\ &\geq f(\mathbf{x}_k) + (\mathbf{x} - \mathbf{x}_k)^T \mathbf{g}_k \\ &= f(\mathbf{x}_k) + \sum_{j=0}^{k-1} (\beta_j - \alpha_j) \mathbf{d}_j^T \mathbf{g}_k \\ &= f(\mathbf{x}_k) \end{aligned}$$



共轭梯度法

共轭梯度法(conjugate gradient method)是一种典型的共轭方向法，搜索方向构造要求如下：

- 所有搜索方向是互相共轭的。
- 搜索方向 \mathbf{d}_k 仅仅是负梯度方向 $-\mathbf{g}_k$ 与上一次迭代的搜索方向 \mathbf{d}_{k-1} 的组合。

记

$$\mathbf{d}_k = -\mathbf{g}_k + \beta_{k-1}\mathbf{d}_{k-1}, \quad (4.3.12)$$

上式两边左乘 $\mathbf{d}_{k-1}^T G$ ，利用方向共轭 $\mathbf{d}_{k-1}^T G \mathbf{d}_k = 0$ 得：

$$\beta_{k-1} = \frac{\mathbf{g}_k^T G \mathbf{d}_{k-1}}{\mathbf{d}_{k-1}^T G \mathbf{d}_{k-1}}. \quad (\text{Hestenes-Stiefel公式}) \quad (4.3.13)$$

共轭梯度法

利用(4.3.8)和(4.3.9),上式也可以写成

$$\beta_{k-1} = \frac{\mathbf{g}_k^T (\mathbf{g}_k - \mathbf{g}_{k-1})}{\mathbf{d}_{k-1}^T (\mathbf{g}_k - \mathbf{g}_{k-1})}, \text{ (Crowder-Wolfe公式)} \quad (4.3.14)$$

$$= \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{g}_{k-1}^T \mathbf{g}_{k-1}}. \text{ (Fletcher-Reeves公式)} \quad (4.3.15)$$

另外三个常用的等价共轭梯度公式

$$\beta_{k-1} = \frac{\mathbf{g}_k^T (\mathbf{g}_k - \mathbf{g}_{k-1})}{\mathbf{g}_{k-1}^T \mathbf{g}_{k-1}}, \quad \text{ (Polak-Ribiere-Polyak公式)} \quad (4.3.16)$$

$$\beta_{k-1} = -\frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{d}_{k-1}^T \mathbf{g}_{k-1}}, \quad \text{ (Dixon公式)}$$

$$\beta_{k-1} = \frac{\mathbf{g}_k^T \mathbf{g}_k}{\mathbf{d}_{k-1}^T (\mathbf{g}_k - \mathbf{g}_{k-1})}. \quad \text{ (Dai-Yuan公式)}$$

共轭梯度法

记:

$$\mathbf{g}_k = G\mathbf{x}_k - \mathbf{b} \triangleq \mathbf{r}_k,$$

由上式以及:

$$\mathbf{g}_k^T \mathbf{d}_k = \mathbf{g}_k^T (-\mathbf{g}_k + \beta_{k-1} \mathbf{d}_{k-1}) = -\mathbf{g}_k^T \mathbf{g}_k = -\mathbf{r}_k^T \mathbf{r}_k$$

得:

$$\mathbf{r}_{k+1} - \mathbf{r}_k = G\mathbf{x}_{k+1} - G\mathbf{x}_k = \alpha_k G\mathbf{d}_k,$$

和

$$\alpha_k = -\frac{\mathbf{g}_k^T \mathbf{d}_k}{\mathbf{d}_k^T G \mathbf{d}_k} = \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{d}_k^T G \mathbf{d}_k},$$

共轭梯度法基本步骤

算法4.3.2 共轭梯度法

步1 初始步:给出 $\mathbf{x}_0, \epsilon > 0$, 计算 $\mathbf{r}_0 = G\mathbf{x}_0 - \mathbf{b}$, 令 $\mathbf{d}_0 = -\mathbf{r}_0, k := 0$.

步2 如果 $\|\mathbf{r}_k\| \leq \epsilon$, 停止。

步3 计算:

$$\begin{aligned}\alpha_k &= \frac{\mathbf{r}_k^T \mathbf{r}_k}{\mathbf{d}_k^T G \mathbf{d}_k}, && \text{步长因子} \\ \mathbf{x}_{k+1} &= \mathbf{x}_k + \alpha_k \mathbf{d}_k, && \text{迭代点} \\ \mathbf{r}_{k+1} &= \mathbf{r}_k + \alpha_k G \mathbf{d}_k && \text{残差} \\ \beta_k &= \frac{\mathbf{r}_{k+1}^T \mathbf{r}_{k+1}}{\mathbf{r}_k^T \mathbf{r}_k}, && \text{组合系数} \\ \mathbf{d}_{k+1} &= -\mathbf{r}_{k+1} + \beta_k \mathbf{d}_k. && \text{共轭方向}\end{aligned}$$

步4 令 $k := k + 1$, 转步2.

注意: 充分利用 $G\mathbf{d}_k$, 可计算因子 α_k 中分母内积向量, 以及迭代方式产生 \mathbf{r}_{k+1} 。另外, $\mathbf{r}_k^T \mathbf{r}_k$ 也可重复利用。

共轭梯度法算例

例4.3.1 用FR共轭梯度法解极小化问题

$$\min f(\mathbf{x}) = \frac{3}{2}x_1^2 + \frac{1}{2}x_2^2 - x_1x_2 - 2x_1.$$

设初始点为: $(0,0)^T$.

解: 目标函数写成矩阵向量乘积形式:

$$f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T G \mathbf{x} - \mathbf{b}^T \mathbf{x}$$

其中:

$$G = \begin{pmatrix} 3 & -1 \\ -1 & 1 \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \quad \mathbf{r}(\mathbf{x}) = G\mathbf{x} - \mathbf{b}.$$

设 $\mathbf{x}_0 = (0,0)^T$,得

$$\mathbf{r}_0 = \begin{pmatrix} -2 \\ 0 \end{pmatrix}, \quad \mathbf{d}_0 = -\mathbf{r}_0 = \begin{pmatrix} 2 \\ 0 \end{pmatrix}, \quad \alpha_0 = \frac{\mathbf{r}_0^T \mathbf{r}_0}{\mathbf{d}_0^T G \mathbf{d}_0} = \frac{1}{3},$$

共轭梯度法算例

解续:

$$\mathbf{x}_1 = \mathbf{x}_0 + \alpha_0 \mathbf{d}_0 = \begin{pmatrix} 0 \\ 0 \end{pmatrix} + \frac{1}{3} \begin{pmatrix} 2 \\ 0 \end{pmatrix} = \begin{pmatrix} \frac{2}{3} \\ 0 \end{pmatrix}$$

$$\mathbf{r}_1 = G\mathbf{x}_1 - \mathbf{b} = \begin{pmatrix} 0 \\ -\frac{2}{3} \end{pmatrix}, \quad \beta_0 = \frac{\mathbf{r}_1^T \mathbf{r}_1}{\mathbf{r}_0^T \mathbf{r}_0} = \frac{1}{9}$$

$$\mathbf{d}_1 = -\mathbf{r}_1 + \beta_0 \mathbf{d}_0 = \begin{pmatrix} 0 \\ \frac{2}{3} \end{pmatrix} + \frac{1}{9} \begin{pmatrix} 2 \\ 0 \end{pmatrix} = \begin{pmatrix} \frac{2}{9} \\ \frac{2}{3} \end{pmatrix}, \quad \alpha_1 = \frac{\mathbf{r}_1^T \mathbf{r}_1}{\mathbf{d}_1^T G \mathbf{d}_1} = \frac{3}{2}$$

$$\mathbf{x}_2 = \mathbf{x}_1 + \alpha_1 \mathbf{d}_1 = \begin{pmatrix} \frac{2}{3} \\ 0 \end{pmatrix} + \frac{3}{2} \begin{pmatrix} \frac{2}{9} \\ \frac{2}{3} \end{pmatrix} = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

$$\mathbf{r}_2 = G\mathbf{x}_2 - \mathbf{b} = \begin{pmatrix} 2 \\ 0 \end{pmatrix} - \begin{pmatrix} 2 \\ 0 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

所以 $\mathbf{x}_2 = (1, 1)^T$ 是所求的极小点。



共轭梯度法的基本性质

定理4.3.2 共轭梯度法基本性质.

对于正定二次函数, 对于任意初始点 $\mathbf{x}_0 \in \mathbb{R}$, 取 $\mathbf{d}_0 = -\mathbf{g}_0$, 采用精确线性搜索的共轭梯度法在 $m \leq n$ 步后终止(二次终止性), 且对 $1 \leq i \leq n$ 成立下列关系式:

$$\text{共轭性: } \mathbf{d}_i^T G \mathbf{d}_j = 0, \quad j = 0, 1, \dots, i-1, \quad (4.3.17a)$$

$$\text{正交性: } \mathbf{g}_i^T \mathbf{g}_j = 0, \quad j = 0, 1, \dots, i-1, \quad (4.3.17b)$$

$$\text{下降性: } \mathbf{d}_i^T \mathbf{g}_i = -\mathbf{g}_i^T \mathbf{g}_i. \quad (4.3.17c)$$

以及:

$$\text{span}\{\mathbf{g}_0, \dots, \mathbf{g}_k\} = \text{span}\{\mathbf{g}_0, G\mathbf{g}_0, \dots, G^k\mathbf{g}_0\} \quad (4.3.17d)$$

$$\text{span}\{\mathbf{d}_0, \dots, \mathbf{d}_k\} = \text{span}\{\mathbf{d}_0, G\mathbf{d}_0, \dots, G^k\mathbf{d}_0\} \quad (4.3.17e)$$

定理4.3.2证明

证明：由共轭方向的推导可得(4.3.17a)式，由(4.3.7)与(4.3.12)可以推导出(4.3.17b)式。由共轭梯度法的定义有：

$$\begin{aligned} \mathbf{d}_k^T \mathbf{g}_k &= (-\mathbf{g}_k + \beta_{k-1} \mathbf{d}_{k-1})^T \mathbf{g}_k \\ &= -\mathbf{g}_k^T \mathbf{g}_k < 0, \end{aligned}$$

即(4.3.17c)成立。

由数学归纳法可以证明(4.3.17d)和(4.3.17e)两式。(略) ■

共轭梯度法收敛速度

可以证明: 共轭梯度产生的点列误差估计:

$$\|\mathbf{x}_k - \mathbf{x}^*\|_G \leq \left(\frac{\sqrt{\kappa(G)} - 1}{\sqrt{\kappa(G)} + 1} \right)^k \|\mathbf{x}_0 - \mathbf{x}^*\|_G. \quad (4.3.18)$$

其中

$$\kappa(G) = \|G\|_2 \|G^{-1}\|_2 = \frac{\lambda_1}{\lambda_n}.$$

共轭梯度法的收敛速度:

- 依赖于 $\sqrt{\kappa(G)}$, 与最速下降法的收敛速度 $\kappa(G)$ 相比, 具有更快的收敛速度。
- 通过改善 G 的条件数, 可加快收敛速度。

非二次函数的共轭梯度法

Fletcher和Reeves(1964)提出了针对非二次函数的共轭梯度法。

算法4.3.3 FR共轭梯度法

步1 给出 $\mathbf{x}_0, \varepsilon > 0, \mathbf{g}_0 = \nabla f(\mathbf{x}_0)$, 令 $\mathbf{d}_0 = -\mathbf{g}_0, k := 0$.

步2 若 $\|\mathbf{g}_k\| \leq \varepsilon$, 停止。

步3 进行一维线性搜索求步长因子 α_k , 并令

$$\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k.$$

步4 $\beta_k = \frac{\mathbf{g}_{k+1}^T \mathbf{g}_{k+1}}{\mathbf{g}_k^T \mathbf{g}_k}$, $\mathbf{d}_{k+1} = -\mathbf{g}_{k+1} + \beta_k \mathbf{d}_k$.

步5 令 $k := k + 1$, 转步2.

Fletcher和Reeves提出在共轭梯度法中使用非精确线性搜索。

特点：程序简单，计算量小，无矩阵存储与计算，适合解大型非线性规划。

FR共轭梯度法的下降性

在非线性的共轭梯度法中，使用精确线性搜索与非精确线性搜索是有区别的。使用精确线性搜索可以保证迭代方向的下降性。若采用非精确线性搜索，FR方法可能产生上升的方向。只有当使用强Wolfe线搜索并保证 $0 < \sigma < 1/2$ 时，得到的方向是下降方向。

定理4.3.3 FR方法的下降性.

对于FR共轭梯度法，若 α_k 满足强Wolfe准则，且 $\sigma \in (0, \frac{1}{2})$ ，则 \mathbf{d}_k 满足：

$$-\frac{1}{1-\sigma} \leq \frac{\mathbf{g}_k^T \mathbf{d}_k}{\|\mathbf{g}_k\|^2} \leq \frac{2\sigma-1}{1-\sigma} \quad (4.3.19)$$

\mathbf{d}_k 是下降方向。

FR共轭梯度法的收敛性

定理4.3.3 FR方法的收敛性.

设 $f(\mathbf{x})$ 有下界, $\mathbf{g}(\mathbf{x})$ 满足Lipschitz条件, 对使用精确线性搜索准则的FR方法, 则或存在 N , 使得 $\mathbf{g}_N = 0$, 或者

$$\liminf_{k \rightarrow \infty} \|\mathbf{g}_k\| = 0.$$