

The background of the slide is a faded photograph of the main entrance gate of Jiaotong University. The gate is a large, white, curved structure with the university's name in English, "JIAOTONG UNIVERSITY", on the right side and in Chinese, "交通大学", on the left. To the left of the gate is a large, brown stone relief sculpture. In the background, there are green trees and a multi-story building with a red roof. A dark purple horizontal bar is overlaid on the middle of the image, containing the title text in yellow.

5-2 非线性最小二乘

非线性最小二乘问题

考虑非线性最小二乘问题

$$\min_{\mathbf{x} \in \mathbb{R}^n} f(\mathbf{x}) = \frac{1}{2} \mathbf{r}(\mathbf{x})^T \mathbf{r}(\mathbf{x}) = \frac{1}{2} \sum_{i=1}^m [r_i(\mathbf{x})]^2, \quad m \geq n, \quad (5.2.1)$$

其中: 剩余函数 $\mathbf{r}(\mathbf{x}) = (r_1(\mathbf{x}), r_2(\mathbf{x}), \dots, r_m(\mathbf{x}))^T$ 为 $\mathbf{x} \in \mathbb{R}^n$ 的非线性函数。

记 $\mathbf{r}(\mathbf{x})$ 的 $m \times n$ 阶 Jacobian 矩阵如下:

$$J(\mathbf{x}) = \begin{bmatrix} \nabla r_1^T(\mathbf{x}) \\ \vdots \\ \nabla r_m^T(\mathbf{x}) \end{bmatrix} = \begin{bmatrix} \frac{\partial r_1}{\partial x_1}(\mathbf{x}) & \frac{\partial r_1}{\partial x_2}(\mathbf{x}) & \cdots & \frac{\partial r_1}{\partial x_n}(\mathbf{x}) \\ \frac{\partial r_2}{\partial x_1}(\mathbf{x}) & \frac{\partial r_2}{\partial x_2}(\mathbf{x}) & \cdots & \frac{\partial r_2}{\partial x_n}(\mathbf{x}) \\ \cdots & \cdots & \cdots & \cdots \\ \frac{\partial r_m}{\partial x_1}(\mathbf{x}) & \frac{\partial r_m}{\partial x_2}(\mathbf{x}) & \cdots & \frac{\partial r_m}{\partial x_n}(\mathbf{x}) \end{bmatrix} \in \mathbb{R}^{m \times n}$$

非线性最小二乘问题

$f(\mathbf{x})$ 的一阶和二阶导数(Hesse矩阵)分别为:

$$\mathbf{g}(\mathbf{x}) = \nabla f(\mathbf{x}) = \sum_{i=1}^m r_i(\mathbf{x}) \nabla r_i(\mathbf{x}) = J(\mathbf{x})^T \mathbf{r}(\mathbf{x}) \quad (5.2.2)$$

$$\begin{aligned} G(\mathbf{x}) = \nabla^2 f(\mathbf{x}) &= \sum_{i=1}^m \nabla r_i(\mathbf{x}) \nabla r_i(\mathbf{x})^T + \sum_{i=1}^m r_i(\mathbf{x}) \nabla^2 r_i(\mathbf{x}) \\ &= J(\mathbf{x})^T J(\mathbf{x}) + S(\mathbf{x}) \end{aligned} \quad (5.2.3)$$

其中:

$$S(\mathbf{x}) = \sum_{i=1}^m r_i(\mathbf{x}) \nabla^2 r_i(\mathbf{x}).$$

这里: $r(\mathbf{x})$ 二阶连续可微。

非线性最小二乘问题

若 \mathbf{x}^* 为最小二乘问题(5.2.1)的最优解, 记:

$$\begin{aligned}J^* &= J(\mathbf{x}^*), J_k = J(\mathbf{x}_k), \\S^* &= S(\mathbf{x}^*), S_k = S(\mathbf{x}_k).\end{aligned}$$

在 \mathbf{x}^* 处, $\|S^*\|$ 的大小取决于剩余量和非线性性:

- 对零剩余量或线性最小二乘问题, $\|S^*\| = 0$;
- 随着剩余量的增大或 $r_i(\mathbf{x})$ 的非线性性增强, $\|S^*\|$ 的值变大。

根据问题的这种特点, 最小二乘算法可分为:

- 小剩余算法: 处理 $\|S^*\|$ 为零或者不大的问题;
- 大剩余算法: 处理 $\|S^*\|$ 较大的问题。

最小二乘问题牛顿法

解最小二乘问题牛顿方程为:

$$(J_k^T J_k + S_k) \mathbf{d}_k = -J_k^T \mathbf{r}_k \quad (5.2.4)$$

牛顿法的缺点: 每次迭代都需要计算 S_k , 涉及到 m 个 $n \times n$ 对称矩阵, 这是一个计算上的很大负担。解决这个问题的办法:

- 或者在牛顿方程中忽略 S_k ,
- 或者用一阶导数信息近似 S_k 。

小剩余算法主要思想: 在 $r_i(\mathbf{x})$ 接近于0或者接近于线性时忽略 S_k 。

(5.2.4)式中忽略 S_k 即可得到**Gauss-Newton方法**。

高斯-牛顿法

从另一个角度理解，在点 \mathbf{x}_k 处线性化剩余函数 $r_i(\mathbf{x}_k + \mathbf{d}) \approx r_i(\mathbf{x}_k) + \nabla r_i(\mathbf{x}_k)^T \mathbf{d}$. 继而得到关于 \mathbf{d} 的线性最小二乘问题：

$$\min_{\mathbf{d} \in \mathbb{R}^n} q_k(\mathbf{d}) = \frac{1}{2} \|J_k \mathbf{d} + \mathbf{r}_k\|_2^2 \quad (5.2.5)$$

其中：

$$q_k(\mathbf{d}) = \frac{1}{2} (J_k \mathbf{d} + \mathbf{r}_k)^T (J_k \mathbf{d} + \mathbf{r}_k) = \frac{1}{2} \mathbf{d}^T J_k^T J_k \mathbf{d} + \mathbf{d}^T (J_k^T \mathbf{r}_k) + \frac{1}{2} \mathbf{r}_k^T \mathbf{r}_k. \quad (5.2.6)$$

这里 $q_k(\mathbf{d})$ 是 $f(\mathbf{x}_k + \mathbf{d})$ 的一种二次近似，与 $f(\mathbf{x}_k + \mathbf{d})$ 的二次Taylor近似的差别在于二次项少了 S_k 。

高斯-牛顿法

问题(5.2.5)的极小点 \mathbf{d}_k 满足:

$$\mathbf{J}_k^T \mathbf{J}_k \mathbf{d} = -\mathbf{J}_k^T \mathbf{r}_k \quad (5.2.7)$$

上式称为Gauss-Newton方程。

算法5.2.1 (Gauss-Newton法)

步1 给定 $\mathbf{x}_0, \varepsilon > 0, k = 0$;

步2 若终止条件满足, 停止迭代;

步3 解方程组 $\mathbf{J}_k^T \mathbf{J}_k \mathbf{d} = -\mathbf{J}_k^T \mathbf{r}_k$ 得 \mathbf{d}_k ;

步4 $\mathbf{x}_{k+1} = \mathbf{x}_k + \alpha_k \mathbf{d}_k, k := k + 1$, 转步2。

当 $\alpha_k = 1$ 时, 以上算法对应基本Gauss-Newton方法。带线搜索的Gauss-Newton方法称为阻尼Gauss-Newton方法。

高斯-牛顿法

Gauss-Newton法充分利用了最小二乘问题的结构特点，仅仅利用函数的一阶导数($J(\mathbf{x})$)的信息直接获得Hesse 矩阵的近似，而无需同拟牛顿方法那样利用函数一阶导数信息的逐步积累来获取Hesse矩阵的近似。

Gauss-Newton方法的优点:

- 无需计算 $\mathbf{r}(\mathbf{x})$ 的二阶导数;
- \mathbf{d}_k 是下降方向。由(5.2.2)式和(5.2.7)式知:

$$\mathbf{d}_k^T \mathbf{g}_k = \mathbf{d}_k^T J_k^T \mathbf{r}_k = -\mathbf{d}_k^T J_k^T J_k \mathbf{d}_k = -\|J_k \mathbf{d}_k\|^2$$

这说明, 当 J_k 满秩, \mathbf{g}_k 非零时, \mathbf{d}_k 是下降方向。

Gauss-Newton收敛性分析

定理5.2.1 Gauss-Newton方法局部收敛性.

设 $r_i(\mathbf{x}) \in C^2 (i = 1, \dots, m)$, \mathbf{x}^* 是最小二乘问题(5.1.1)的最优解, 且 $J^{*T}J^*$ 正定。假定基本Gauss-Newton方法产生的迭代点列 $\{\mathbf{x}_k\}$ 收敛于 \mathbf{x}^* , 则当 $G(\mathbf{x})$ 和 $J(\mathbf{x})^T J(\mathbf{x})$ 在 \mathbf{x}^* 的邻域内Lipschitz连续时, 有:

$$\|\mathbf{h}_{k+1}\| \leq \|(J^{*T}J^*)^{-1}\| \|S^*\| \|\mathbf{h}_k\| + O(\|\mathbf{h}_k\|^2) \quad (5.2.8)$$

其中: $\mathbf{h}_k = \mathbf{x}_k - \mathbf{x}^*$ 。

证明: 因为 $f \in C^2$, 且 $G(\mathbf{x})$ 在 \mathbf{x}^* 邻域内Lipschitz连续, 当 \mathbf{x}_k 充分接近 \mathbf{x}^* 时, 由牛顿法收敛性定理 (教材50页, 定理3.5) 证明知:

$$\mathbf{g}(\mathbf{x}_k + \mathbf{d}) = \mathbf{g}_k + G_k \mathbf{d} + O(\|\mathbf{d}\|^2) \quad (\text{a})$$

定理5.2.1证明

证明续： 令 $\mathbf{d} = -\mathbf{h}_k$, 得

$$0 = \mathbf{g}^* = \mathbf{g}_k - G_k \mathbf{h}_k + O(\|\mathbf{h}_k\|^2) \quad (\text{b})$$

由(5.2.2)和(5.2.3)两式计算 \mathbf{g}_k 和 G_k 代入上式得：

$$J_k^T \mathbf{r}_k - (J_k^T J_k + S_k) \mathbf{h}_k + O(\|\mathbf{h}_k\|^2) = 0. \quad (\text{c})$$

由于 $J^{*T} J^*$ 正定, 当 \mathbf{x}_k 充分靠近 \mathbf{x}^* 时, $J_k^T J_k$ 亦正定。用 $(J_k^T J_k)^{-1}$ 左乘(c)式由(5.2.7)式得：

$$-\mathbf{d}_k - \mathbf{h}_k - (J_k^T J_k)^{-1} S_k \mathbf{h}_k + O(\|\mathbf{h}_k\|^2) = 0.$$

又因为：

$$\mathbf{d}_k + \mathbf{h}_k = \mathbf{x}_{k+1} - \mathbf{x}_k + \mathbf{x}_k - \mathbf{x}^* = \mathbf{h}_{k+1}$$

定理5.2.1证明

证明续：所以：

$$\begin{aligned}\|\mathbf{h}_{k+1}\| &\leq \|(J_k^T J_k)^{-1} S_k\| \|\mathbf{h}_k\| + O(\|\mathbf{h}_k\|^2) \\ &\leq \|(J_k^T J_k)^{-1} S_k - (J^{*T} J^*)^{-1} S^*\| \|\mathbf{h}_k\| \\ &\quad + \|(J^{*T} J^*)^{-1}\| \|S^*\| \|\mathbf{h}_k\| + O(\|\mathbf{h}_k\|^2)\end{aligned}\quad (\text{d})$$

下证 $S(\mathbf{x})$ 与 $(J(\mathbf{x})^T J(\mathbf{x}))^{-1}$ 在 \mathbf{x}^* 的邻域内Lipschitz连续。对于矩阵 $A(\mathbf{x})$ ，采用记号： $A(\mathbf{x}) = A_{\mathbf{x}}$ 。因为 $G_{\mathbf{x}}$ 和 $J_{\mathbf{x}}^T J_{\mathbf{x}}$ 在 \mathbf{x}^* 的邻域内Lipschitz连续，所以存在 $\beta, \gamma > 0$ ，使得对 \mathbf{x}^* 的邻域内任意两点 \mathbf{x}, \mathbf{y} ，有：

$$\|G_{\mathbf{x}} - G_{\mathbf{y}}\| \leq \beta \|\mathbf{x} - \mathbf{y}\|, \quad \|J_{\mathbf{x}}^T J_{\mathbf{x}} - J_{\mathbf{y}}^T J_{\mathbf{y}}\| \leq \gamma \|\mathbf{x} - \mathbf{y}\|$$

从而：

$$\begin{aligned}\|S_{\mathbf{x}} - S_{\mathbf{y}}\| &= \|G_{\mathbf{x}} - G_{\mathbf{y}} - J_{\mathbf{x}}^T J_{\mathbf{x}} + J_{\mathbf{y}}^T J_{\mathbf{y}}\| \leq \|G_{\mathbf{x}} - G_{\mathbf{y}}\| + \|J_{\mathbf{x}}^T J_{\mathbf{x}} - J_{\mathbf{y}}^T J_{\mathbf{y}}\| \\ &\leq (\beta + \gamma) \|\mathbf{x} - \mathbf{y}\|\end{aligned}$$

定理5.2.1证明

证明续: 对 \mathbf{x}^* 邻域内的任意点 \mathbf{x} , 由于 $J^{*T}J^*$ 的正定性知, 存在 $\xi > 0$, 使得 $\|(J_{\mathbf{x}}^T J_{\mathbf{x}})^{-1}\| \leq \xi$, 从而:

$$\begin{aligned}\|(J_{\mathbf{x}}^T J_{\mathbf{x}})^{-1} - (J_{\mathbf{y}}^T J_{\mathbf{y}})^{-1}\| &= \|(J_{\mathbf{x}}^T J_{\mathbf{x}})^{-1}(J_{\mathbf{y}}^T J_{\mathbf{y}} - J_{\mathbf{x}}^T J_{\mathbf{x}})(J_{\mathbf{y}}^T J_{\mathbf{y}})^{-1}\| \\ &\leq \|(J_{\mathbf{x}}^T J_{\mathbf{x}})^{-1}\| \|(J_{\mathbf{y}}^T J_{\mathbf{y}})^{-1}\| \|(J_{\mathbf{y}}^T J_{\mathbf{y}} - J_{\mathbf{x}}^T J_{\mathbf{x}})\| \\ &\leq \gamma \xi^2 (\|\mathbf{x} - \mathbf{y}\|)\end{aligned}$$

所以 $S_{\mathbf{x}}$ 与 $(J_{\mathbf{x}}^T J_{\mathbf{x}})^{-1}$ 在 \mathbf{x}^* 的邻域内Lipschitz连续。

当 \mathbf{x}_k 充分靠近 \mathbf{x}^* 时, 有:

$$\begin{aligned}\|(J_k^T J_k)^{-1} S_k - (J^{*T} J^*)^{-1} S^*\| &\leq \|(J_k^T J_k)^{-1} S_k - (J_k^T J_k)^{-1} S^*\| \\ &\quad + \|(J_k^T J_k)^{-1} S^* - (J^{*T} J^*)^{-1} S^*\| \\ &\leq (\beta + \gamma) \|(J_k^T J_k)^{-1}\| \|\mathbf{h}_k\| + \gamma \xi^2 \|S^*\| \|\mathbf{h}_k\| \\ &\leq ((\beta + \gamma)\xi + \gamma \xi^2 \|S^*\|) \|\mathbf{h}_k\|\end{aligned}$$

定理5.2.1证明

证明续： 代入(d)式得：

$$\|\mathbf{h}_{k+1}\| \leq \|(J^{*T}J^*)^{-1}\| \|S^*\| \|\mathbf{h}_k\| + O(\|\mathbf{h}_k\|^2)$$

故结论成立。 ■

该定理说明：若 $\mathbf{x}_k \rightarrow \mathbf{x}^*$ ，基本Gauss-Newton方法有如下两种情形得收敛速度：

- 二阶收敛速度. 若 $\|S(\mathbf{x}^*)\| = 0$ ，即在零剩余问题或者线性最小二乘情形，则方法在 \mathbf{x}^* 附近具有Newton方法得收敛速度。
- 线性收敛速度. 若 $\|S(\mathbf{x}^*)\| \neq 0$ ，则方法的收敛速度是线性的，收敛速度随着 $\|S^*\|$ 的增大而变慢。


注意： 对于剩余量很大或者剩余函数非线性程度很强的问题，Gauss-Newton方法可能不收敛。

例题收敛性分析

例5.2.1 (教材125页) 考虑最小二乘问题:

$$\min f(\mathbf{x}) = \frac{1}{2}[(x+1)^2 + (\lambda x^2 + x - 1)^2], x \in \mathbb{R}$$

该问题当 $\lambda < 1$ 时, 有全局解 $x^* = 0$.



在 $\lambda = 0.1$ (上)与 $\lambda = -1$ (下)两种情形下, $f(\mathbf{x})$ 的图像(左)与 $\{\log |x_k|\}$ 的轨迹(右)

阻尼高斯-牛顿法

定理5.2.2 阻尼高斯-牛顿法全局收敛性.

设有界水平集 $L(\mathbf{x}_0) = \{\mathbf{x} | f(\mathbf{x}) \leq f(\mathbf{x}_0)\}$ 上, $r_i(\mathbf{x}) (i = 1, \dots, m)$ 连续可微, $J(\mathbf{x})$ 列满秩, 则对采用Wolfe准则的阻尼Gauss-Newton方法产生的 $\{\mathbf{x}_k\}$, 或者存在 N , 使得 $\mathbf{g}_N = 0$, 或者 $\mathbf{g}_k \rightarrow 0, k \rightarrow \infty$.

证明: 由于 $L(\mathbf{x}_0)$ 是有界闭集, 故 $\mathbf{g}(\mathbf{x})$ 在 $L(\mathbf{x}_0)$ 上一致连续. 由非精确线性搜索收敛性定理(教材24页, 定理2.8), 只需要证明 \mathbf{d}_k 和 $-\mathbf{g}_k$ 之间的夹角一致有界.

由 $r_i(\mathbf{x})$ 在 $L(\mathbf{x}_0)$ 上连续可微知, 存在 $\xi > 0$, 使对任意 $\mathbf{x} \in L(\mathbf{x}_0)$, 有 $\|\nabla r_i(\mathbf{x})\| \leq \xi, i = 1, \dots, m$, 从而:

$$\|J(\mathbf{x})\|_{\infty} = \max_{1 \leq i \leq m} \sum_{j=1}^n \left| \frac{\partial r_i(\mathbf{x})}{\partial x_j} \right| \leq \xi, \forall \mathbf{x} \in L(\mathbf{x}_0)$$

定理5.2.2证明

证明续: 由范数的等价性知, 存在 $\bar{\xi} > 0$, 使得:

$$\|J(\boldsymbol{x})\| = \|J(\boldsymbol{x})^T\| \leq \bar{\xi}$$

由Gauss-Newton方程可得:

$$\cos \theta_k = -\frac{\boldsymbol{g}_k^T \boldsymbol{d}_k}{\|\boldsymbol{g}_k\| \|\boldsymbol{d}_k\|} = -\frac{\boldsymbol{r}_k^T J_k \boldsymbol{d}_k}{\|J_k^T \boldsymbol{r}_k\| \|\boldsymbol{d}_k\|} = \frac{\|J_k \boldsymbol{d}_k\|^2}{\|J_k^T J_k \boldsymbol{d}_k\| \|\boldsymbol{d}_k\|} \geq \frac{\delta^2}{\xi^2} > 0$$

由非精确线性搜索收敛性定理(教材定理2.8)知结论成立。 ■

定理5.2.2要求 $J(\boldsymbol{x})$ 列满秩, 否则 $J(\boldsymbol{x})^T J(\boldsymbol{x})$ 奇异, 此时不能从Gauss-Newton方程(5.2.7)式中解出 \boldsymbol{d}_k .

Gauss-Newton方程求解

线性最小二乘问题(5.2.6)求解和Gauss-Newton方程(5.2.7)求解是等价的。注意两者中相应矩阵 J 与 $J^T J$ 条件数有如下关系：

$$\text{cond}^2(J) = \text{cond}(J^T J)$$

因此，Gauss-Newton方程(5.2.7)条件数是最小二乘问题(5.2.6)条件数的平方，这使得采用Gauss-Newton方程求解过程增加了对舍入误差的敏感性，直接求解问题(5.2.6)可避免这个问题。

求解的方法使用正交化方法，考虑2范数的正交不变性有：

$$\|J_k \mathbf{d} + \mathbf{r}_k\| = \|Q_k^T (J_k \mathbf{d} + \mathbf{r}_k)\|.$$

其中： $Q_k \in \mathbb{R}^{m \times m}$ 为任意正交矩阵。

Gauss-Newton方程求解

求解问题(5.2.6)等价于求解:

$$\min \frac{1}{2} \|Q_k^T (J_k \mathbf{d} + \mathbf{r}_k)\|^2.$$

首先对于 J_k 进行QR分解:

$$J_k = Q_k \begin{bmatrix} R_k \\ \mathbf{0} \end{bmatrix} \quad (5.2.9)$$

其中: $Q_k \in \mathbb{R}^{m \times m}$ 为正交阵, $R_k \in \mathbb{R}^{n \times n}$ 是具有非负对角元的上三角阵, $\mathbf{0} \in \mathbb{R}^{(m-n) \times m}$ 是零矩阵。进一步对 Q_k 进行分块:

$$Q_k = \begin{bmatrix} (Q_1^{(k)})_{m \times n} & (Q_2^{(k)})_{m \times (m-n)} \end{bmatrix}$$

Gauss-Newton方程求解

令:

$$Q_k^T \mathbf{r}_k = \begin{bmatrix} Q_1^{(k)T} \\ Q_2^{(k)T} \end{bmatrix} \mathbf{r}_k = \begin{bmatrix} \mathbf{b}_1 \\ \mathbf{b}_2 \end{bmatrix} \begin{matrix} n \\ m-n \end{matrix}$$

则:

$$\|J_k \mathbf{d} + \mathbf{r}_k\|^2 = \|Q_k^T J_k \mathbf{d} + Q_k^T \mathbf{r}_k\|^2 = \|R_k \mathbf{d} + \mathbf{b}_1\|^2 + \|\mathbf{b}_2\|^2$$

由此可知, \mathbf{d}_k 是最小二乘问题(5.2.6)的解当且仅当 \mathbf{d}_k 是 $R_k \mathbf{d} = -\mathbf{b}_1$ 的解。综上所述, 利用QR分解求最小二乘问题(5.2.6)的解的基本步骤:

- 计算 J_k 的QR分解(5.2.9);
- 计算 $\mathbf{b}_1 = Q_1^{(k)T} \mathbf{r}_k$;
- 求解上三角方程组 $R_k \mathbf{d} = -\mathbf{b}_1$, 即得到 \mathbf{d}_k 。