

The background of the slide is a faded photograph of the main entrance gate of Xi'an Jiaotong University (XJTU). The gate is a large, white, curved structure with the university's name in Chinese characters '交通大学' and English 'XIAOTONG UNIVERSITY' inscribed on it. To the left of the gate is a stone wall with a large, intricate relief sculpture. Several people are visible walking through the gate. The overall scene is bright and clear.

5-3 LMF方法与Dogleg方法

Gauss-Newton方法在迭代过程中会出现 $J_k^T J_k$ 为奇异的情形。为了克服这个困难，Levenberg在1944年提出了求解如下方程获得 \mathbf{d}_k :

$$(J_k^T J_k + \nu_k I) \mathbf{d} = -J_k^T \mathbf{r}_k \quad (5.3.1)$$

其中： $\nu_k \geq 0$ 。1964年，这个方法经Marquardt的努力获得广泛应用，故称为LM(Levenberg-Marquardt)方法。(5.3.1)式也称为LM方程。

LM方程中，对任意 $\nu_k > 0$ ， $J_k^T J_k + \nu_k I$ 正定，从而保证了(5.3.1)方程中得到的方向是下降方向。从计算的角度出发， ν_k 的值可需要取得合适的大，保证 $J_k^T J_k + \nu_k I$ 充分正定。

LM方法是一种信赖域方法， ν_k 的值可以用信赖域方法的思想在迭代中修正得到。只要找出LM方程与信赖域问题的关系，就可以根据修正信赖域半径的方法来修正 ν_k 的值。

定理5.3.1 LM方程与信赖域问题的关系.

\mathbf{d}_k 为信赖域子问题:

$$\min_{\mathbf{d}} \quad \frac{1}{2} \|J_k \mathbf{d} + \mathbf{r}_k\|^2, \quad (5.3.2a)$$

$$\text{s.t.} \quad \|\mathbf{d}\|^2 \leq \Delta_k^2, \Delta_k > 0 \quad (5.3.2b)$$

的全局极小解的充要条件是, 对满足(5.3.2b)的 \mathbf{d}_k , 存在 $\nu_k \geq 0$, 使得:

$$(J_k^T J_k + \nu_k I) \mathbf{d}_k = -J_k^T \mathbf{r}_k \quad (5.3.3a)$$

$$\nu_k (\Delta_k^2 - \|\mathbf{d}_k\|^2) = 0. \quad (5.3.3b)$$

证明: 必要性 由约束优化问题的最优性条件, Lagrange函数:

$$L(\mathbf{d}, \nu) = q_k(\mathbf{d}) - \frac{1}{2} \nu (\Delta_k^2 - \|\mathbf{d}\|^2)$$

定理5.3.1证明

证明续： **必要性** 存在 $\nu_k \geq 0$, 使得 (\mathbf{d}_k, ν_k) 是如下Lagrange函数 $L(\mathbf{d}, \nu)$ 的KKT对。这里: $q_k(\mathbf{d}) = \frac{1}{2} \|J_k \mathbf{d} + \mathbf{r}_k\|^2$ 。

(\mathbf{d}_k, ν_k) 满足:

$$\nabla_{\mathbf{d}} L(\mathbf{d}_k, \nu_k) = 0 \Rightarrow J_k^T \mathbf{r}_k + (J_k^T J_k + \nu_k I) \mathbf{d}_k = 0$$

即得到(5.3.3a)式。由互补条件得: $\nu_k(\Delta_k^2 - \|\mathbf{d}_k\|^2) = 0$, 即(5.3.3b)式。

充分性 因为 $J_k^T J_k + \nu_k I$ 半正定, 所以方程(5.3.3a)的解 \mathbf{d}_k 是如下二次函数全局极小点:

$$\tilde{q}_k(\mathbf{d}) = \frac{1}{2} \mathbf{d}^T (J_k^T J_k + \nu_k I) \mathbf{d} + \mathbf{d}^T (J_k^T \mathbf{r}_k) + \frac{1}{2} \mathbf{r}_k^T \mathbf{r}_k$$

定理5.3.1证明

证明续: 由(5.2.6)式中 $q_k(\mathbf{d})$ 计算公式知:

$$\tilde{q}_k(\mathbf{d}) = q_k(\mathbf{d}) + \frac{1}{2}\nu_k\|\mathbf{d}\|^2$$

对任意 $\mathbf{d} \in \mathbb{R}^n$, 都有 $\tilde{q}_k(\mathbf{d}) \geq \tilde{q}_k(\mathbf{d}_k)$, 所以:

$$q_k(\mathbf{d}) \geq q_k(\mathbf{d}_k) + \frac{1}{2}\nu_k(\|\mathbf{d}_k\|^2 - \|\mathbf{d}\|^2).$$

由(5.3.3b)知, 若 $\nu_k = 0$, 有: $q_k(\mathbf{d}) \geq q_k(\mathbf{d}_k)$; 若 $\nu_k \neq 0$, 有: $\|\mathbf{d}_k\|^2 = \Delta_k^2$, 继而有:

$$q_k(\mathbf{d}) \geq q_k(\mathbf{d}_k) + \frac{1}{2}(\Delta_k^2 - \|\mathbf{d}\|^2)$$

这说明, 对任意 $\nu_k \geq 0$ 和任意满足 $\|\mathbf{d}\|^2 \leq \Delta_k^2$ 的 \mathbf{d} , \mathbf{d}_k 都是问题(5.3.2)的全局最优解。 ■

LMF方法

LM方程与信赖域问题的关系是Fletcher于1981年提出的，故由此建立起来的方法称为LMF(Levenberge-Marquardt-Fletcher)方法。

ν_k 的修正方法与信赖域半径 Δ_k 修正是相关的。在信赖域方法中，从 \mathbf{x}_k 到 $\mathbf{x}_k + \mathbf{d}_k$ 的实际减少量为：

$$\Delta f_k = f(\mathbf{x}_k) - f(\mathbf{x}_k + \mathbf{d}_k)$$

$f(\mathbf{x}_k + \mathbf{d})$ 的二次近似函数 $q_k(\mathbf{d})$ 的减少量为：

$$\Delta q_k = q_k(0) - q_k(\mathbf{d}_k)$$

这里 $q_k(0) = f_k$ 。

另外，由LM方程以及 $\mathbf{d}_k^T \mathbf{g}_k < 0$ 知：

$$\begin{aligned}\Delta q_k &= q_k(0) - q_k(\mathbf{d}_k) \\&= -\frac{1}{2} \mathbf{d}_k^T J_k^T J_k \mathbf{d}_k - \mathbf{d}_k^T (J_k^T \mathbf{r}_k) \\&= \frac{1}{2} \mathbf{d}_k^T (-J_k^T J_k \mathbf{d}_k - \nu_k \mathbf{d}_k + \nu_k \mathbf{d}_k - 2J_k^T \mathbf{r}_k) \\&= \frac{1}{2} \mathbf{d}_k^T (-(J_k^T J_k + \nu_k) \mathbf{d}_k + \nu_k \mathbf{d}_k - 2J_k^T \mathbf{r}_k) \\&= \frac{1}{2} \mathbf{d}_k^T (\nu_k \mathbf{d}_k - \mathbf{g}_k) > 0\end{aligned}\tag{5.3.4}$$

其中： $\mathbf{g}_k = J_k^T \mathbf{r}_k$. (公式(5.2.2) or 教材120页-公式(5.3))

LMF方法

定义:

$$\gamma_k = \frac{\Delta f_k}{\Delta q_k} \quad (5.3.5)$$

比值 γ_k 可以反映出 $q_k(\mathbf{d}_k)$ 近似 $f(\mathbf{x}_k + \mathbf{d}_k)$ 的好坏，在上一章中信赖域方法已经讨论过。

由LM方程知, ν_k 可以控制 $\|\mathbf{d}_k\|$ 的大小，从而控制信赖域的大小。若 ν_k 变大的化， $\|\mathbf{d}_k\|$ 会变小，反之亦然，所以对 ν_k 的大小修正，应该与信赖域方法中对于信赖域半径 Δ_k 的修正相反。

LMF方法

算法5.3.1 LMF方法

步1 给出 $\mathbf{x} \in \mathbb{R}^n$, $\nu_0 > 0, \varepsilon > 0, k := 0$.

步2 若终止条件满足, 则输出结果, 停止迭代.

步3 求解LM方程(5.3.1)得 \mathbf{d}_k .

步4 由(5.3.5)计算比值 γ_k .

步5 若 $\gamma_k < 0.25$, 则 $\nu_{k+1} := 4\nu_k$; 若 $\gamma_k > 0.75$, 则 $\nu_{k+1} = \frac{1}{2}\nu_k$; 否则, $\nu_{k+1} := \nu_k$.

步6 若 $\gamma_k \leq 0$, 则 $\mathbf{x}_{k+1} := \mathbf{x}_k$; 否则, $\mathbf{x}_{k+1} = \mathbf{x}_k + \mathbf{d}_k, k := k + 1$, 转步2.

LMF方法与修正牛顿方法

LMF方法可以用于求解一般无约束优化问题。在修正牛顿法中，修正牛顿方程和信赖域问题的关系如下：

定理5.3.2 修正牛顿方程与信赖域问题的关系.

\mathbf{d}_k 为信赖域子问题：

$$\min_{\mathbf{d}} q_k(\mathbf{d}) \quad (5.3.6a)$$

$$\text{s.t. } \|\mathbf{d}\|^2 \leq \Delta_k^2, \Delta_k > 0 \quad (5.3.6b)$$

的全局极小解的充分必要条件是，对满足(5.3.6b)的 \mathbf{d}_k ，存在 $\nu_k \geq 0$ ，使得：

$$(G_k + \nu_k I)\mathbf{d}_k = -\mathbf{g}_k \quad (5.3.7a)$$

$$\nu_k(\Delta_k^2 - \|\mathbf{d}_k\|^2) = 0 \quad (5.3.7b)$$

$$G_k + \nu_k I \text{ 半正定} \quad (5.3.7c)$$

Dogleg方法

在LM方法中，由LM方程得到的方向 \mathbf{d}_k^{LM} 受到 ν_k 取值的影响。当 ν_k 很大时， \mathbf{d}_k^{LM} 偏向于负梯度方向；若 ν_k 很小，则 \mathbf{d}_k^{LM} 接近Gauss-Newton方向；否则， \mathbf{d}_k^{LM} 介于负梯度方向和Gauss-Newton方向之间。受此影响的启示，1970年Powell提出解如下信赖域子问题的Dogleg方法

$$\min \quad \frac{1}{2} \|\mathbf{J}_k \mathbf{d} + \mathbf{r}_k\|^2 \quad (5.3.8a)$$

$$\text{s.t.} \quad \|\mathbf{d}\| \leq \Delta_k, \Delta_k > 0 \quad (5.3.8b)$$

\mathbf{d}_k^{GN} 与 \mathbf{d}_k^{SD} 分别由Gauss-Newton方程或者最速下降方向给出。最速下降法的步长为：

$$\alpha_k = \arg \min q_k(\alpha \mathbf{d}_k^{\text{SD}}) = \frac{\|\mathbf{d}_k^{\text{SD}}\|^2}{\|\mathbf{J}_k \mathbf{d}_k^{\text{SD}}\|^2}$$

其中： $q_k(\alpha \mathbf{d}_k^{\text{SD}}) \triangleq \frac{1}{2} \|\alpha \mathbf{J}_k \mathbf{d}_k^{\text{SD}} + \mathbf{r}_k\|^2 = \frac{1}{2} \|\mathbf{J}_k \mathbf{d}_k^{\text{SD}}\|^2 \alpha^2 - \|\mathbf{d}_k^{\text{SD}}\|^2 \alpha + f_k$.


算法5.3.2 Dogleg方法求解最小二乘信赖域子问题

步1 给出 $\Delta_k > 0, J_k, r_k$;


步2 若 $\|d_k^{\text{GN}}\| \leq \Delta_k$, 则 $d_k = d_k^{\text{GN}}$, 输出 d_k , 迭代停止;

步3 若 $\alpha_k \|d_k^{\text{SD}}\| \geq \Delta_k$, 则 $d_k = \frac{\Delta_k}{\|d_k^{\text{SD}}\|} d_k^{\text{SD}}$, 输出 d_k , 迭代停止;


步4 计算 $d_k = (1 - \beta)\alpha_k d_k^{\text{SD}} + \beta d_k^{\text{GN}}$, 其中要确定 β 使得 $\|d_k\| = \Delta_k$, 输出 d_k , 迭代停止。



(a)



(b)



(c)

在算法5.3.2中

- 步3中 $\alpha_k \|\mathbf{d}_k\| \geq \Delta_k$ 意味着 Δ_k 相对较小, 即 $\|\mathbf{d}_k^{\text{LM}}\|$ 比较小, 此时对应 ν_k 比较大, 因此选择下降方向来确定 \mathbf{d}_k 。
- 若 J_k 列满秩, 则 $J_k^T J_k$ 正定, Gauss-Newton方程有解。另外, 只要 $\mathbf{r}_k \neq 0$, \mathbf{d}_k^{SD} 就是下降方向。因此, Dogleg方法适合解决 J_k 列满秩的信赖域子问题。
- 欲使得 $\|\mathbf{d}_k\| = \Delta_k$, 即求函数

$$\tilde{q}(\beta) = \|\alpha_k \mathbf{d}_k^{\text{SD}} + (\mathbf{d}_k^{\text{GN}} - \alpha_k \mathbf{d}_k^{\text{SD}})\beta\|^2 - \Delta_k^2$$

的零点。

大剩余量问题

Gauss-Newton方法时在Newton方法的Hesse阵中忽略了二阶项 $S(\mathbf{x}) = \sum_{i=1}^m r_i(\mathbf{x}) \nabla^2 r_i(\mathbf{x})$ 得到的。对于剩余量大或者剩余函数的非线性程度很高的问题，忽略二阶项会影响算法的收敛性和收敛速度。如果不忽略而直接计算二阶导数矩阵，将涉及到很大计算复杂性。

与拟牛顿法类似，利用一阶梯度信息构造 $S(\mathbf{x})$ 的近似矩阵 \hat{B} 。假定点 \mathbf{x}_k 已得到 S_k 的近似矩阵 \hat{B}_k ，在点 \mathbf{x}_{k+1} 处满足什么条件的 \hat{H}_{k+1} 可以作为 S_{k+1} 的近似矩阵，使得：

$$J_{k+1}^T J_{k+1} + \hat{B}_{k+1} \approx G_{k+1}$$

这里 \hat{B}_{k+1} 应该满足：

$$\hat{B}_{k+1} \mathbf{s}_k = \hat{\mathbf{y}}_k$$

其中： $\hat{\mathbf{y}}_k = (J_{k+1} - J_k)^T \mathbf{r}_{k+1}$ 。

大剩余量问题

类似于拟牛顿法，在所有对称、满足拟牛顿条件矩阵中，寻找在加权范数意义下与 \hat{B}_k 的差最小的矩阵，即考虑如下问题：

$$\begin{aligned} \min_{\hat{B}} \quad & \|W^{-T}(\hat{B} - \hat{B}_k)W^{-1}\|_F \\ \text{s.t.} \quad & \hat{B} = \hat{B}^T, \hat{B}\mathbf{s}_k = \hat{\mathbf{y}}_k \end{aligned}$$

其中 $W \in \mathbb{R}^{n \times n}$ ， $W^T W$ 满足拟牛顿条件 $W^{-T} W \mathbf{s}_k = \mathbf{y}_k$ 。该问题的解为：

$$\hat{B}_{k+1} = \hat{B}_k + \frac{(\hat{\mathbf{y}}_k - \hat{B}_k \mathbf{s}_k) \mathbf{y}_k^T + \mathbf{y}_k (\hat{\mathbf{y}}_k - \hat{B}_k \mathbf{s}_k)^T}{\mathbf{y}_k^T \mathbf{s}_k} - \frac{(\hat{\mathbf{y}}_k - \hat{B}_k \mathbf{s}_k)^T \mathbf{s}_k}{(\mathbf{y}_k^T \mathbf{s}_k)^2} \mathbf{y}_k \mathbf{y}_k^T.$$

其中：

$$\begin{aligned} \mathbf{s}_k &= \mathbf{x}_{k+1} - \mathbf{x}_k \\ \mathbf{y}_k &= J_{k+1}^T \mathbf{r}_{k+1} - J_k^T \mathbf{r}_k \\ \hat{\mathbf{y}}_k &= (J_{k+1} - J_k)^T \mathbf{r}_{k+1}. \end{aligned}$$