


The background of the slide is a faded photograph of the main entrance gate of Jiaotong University. The gate is a large, white, curved structure with the university's name in English, "JIAOTONG UNIVERSITY", on the right side and in Chinese, "交通大学", on the left. To the left of the gate is a large, brown stone relief sculpture. In the background, there are green trees and a multi-story building with a red roof. A dark purple horizontal bar is overlaid on the middle of the image, containing the title text in yellow.


## 6-4 增广拉格朗日方法

# 罚函数病态条件


罚函数中参数 $\sigma$ 增大将使得罚函数子问题最优解与原约束优化问题最优解趋于一致, 同时也带来了对应二阶Hesse矩阵病态的问题特征, 不利于算法的稳定性。




(a)  $\sigma=5$



(b)  $\sigma=25$



(c)  $\sigma=100$



(d)  $\sigma=1000$

# 建立增广拉格朗日方法思想

外点罚函数方法的主要问题:

- $\sigma_k \rightarrow \infty$ 所引起的无约束最优化问题的病态性。若可以构造出来某种函数, 不要求 $\sigma_k \rightarrow \infty$ ;
- 或者只要 $\sigma_k$ 足够大, 此函数的极小点为原问题的最优解, 则可以避免病态问题出现.

如何构造这种函数? 假定这种函数形式为 $\Phi(\mathbf{x}, \sigma)$ , 其中 $\sigma > 0$ 为给定参数. 希望优化如下问题:

$$\min_{\mathbf{x}} \Phi(\mathbf{x}, \sigma)$$

得到原问题的最优解 $\mathbf{x}^*$ 。

# 增广拉格朗日方法

根据无约束最优化问题目标函数在最优解处应满足条件来构造。具体地，在 $\mathbf{x}^*$ 处， $\Phi(\mathbf{x}, \sigma)$ 应满足一阶最优性条件：

$$\nabla_{\mathbf{x}}\Phi(\mathbf{x}^*, \sigma) = 0$$

和二阶最优性条件（基于方向导数）

$$\frac{\partial^2 \Phi(\mathbf{x}^*, \sigma)}{\partial \mathbf{d}^2} > 0, \mathbf{d} \in \mathbb{R}^n \setminus \{0\}$$

其中 $\mathbf{d}$ 为 $\mathbf{x}^*$ 处任意非零方向.

# 检验罚函数是否满足条件

考虑罚函数

$$P_E(\mathbf{x}, \sigma) = f(\mathbf{x}) + \frac{1}{2}\sigma \sum_{i \in \mathcal{E}} c_i^2(\mathbf{x})$$

计算其在可行点 $\mathbf{x}^*$ 处的梯度:


$$\nabla P_E(\mathbf{x}^*, \sigma) = \nabla f(\mathbf{x}^*) + \sigma \sum_{i \in \mathcal{E}} \nabla c_i(\mathbf{x}^*) c_i(\mathbf{x}^*) = \nabla f(\mathbf{x}^*)$$

在罚因子固定的情况下,  $\nabla f(\mathbf{x}^*) \neq 0$ , 故 $\mathbf{x}^*$ 不是无约束最优化问题的最优解, 一般不能够通过求罚函数极小点得到原问题最优解.

# 检验拉格朗日函数

再看拉格朗日函数 $L(\boldsymbol{x}, \boldsymbol{\lambda})$ :

- 存在KKT点 $\boldsymbol{x}^*$ 与对应的Lagrange乘子 $\boldsymbol{\lambda}^*$ , 必然满足一阶最优性条件.
- 对含有一个等式约束的问题为例, 二阶条件不成立, 如下图



$L(\boldsymbol{x}, \boldsymbol{\lambda}^*)$ 在 $\boldsymbol{x}^*$ 处仅沿着:

$$\boldsymbol{c}(\boldsymbol{x}) = 0$$

的切线方向 $\boldsymbol{d}$ 的二阶方向导数为正, 其他方向均为负.

# 增广拉格朗日函数

构造思想:

在 $\mathbf{x}^*$ 附近,  $L(\mathbf{x}, \boldsymbol{\lambda}^*)$ 沿着方向 $\mathbf{d}$ 的函数曲面保持不变, 其余部分的函数曲面向上拉起, 使得函数在 $\mathbf{x}^*$ 处沿着任意方向的二阶方向导数均为正。这相当于当变量离开约束时, 就加大 $L(\mathbf{x}, \boldsymbol{\lambda}^*)$ 的函数值. 这正是构造罚函数的思想.

增广形式:

$$\Phi(\mathbf{x}, \boldsymbol{\lambda}, \sigma) = f(\mathbf{x}) - \boldsymbol{\lambda}^T \mathbf{c}(\mathbf{x}) + \frac{1}{2}\sigma \sum_{i \in \mathcal{E}} c_i^2(\mathbf{x}). \quad (6.4.1)$$

该函数也可以理解为在罚函数基础上增加了乘子项得到的, 故又称为**乘子罚函数法**.

# 增广拉格朗日函数变化情况

例6.4.1 考虑等式约束优化问题:

$$\begin{array}{ll}\min & f(x) = 2x_1^2 - x_2^2 + x_1 - x_2 \\ \text{s.t.} & x_1 - x_2 = 0\end{array}$$

分析: 以上问题的Lagrange函数形式为:

$$L(\mathbf{x}, \lambda) = 2x_1^2 - x_2^2 + x_1 - x_2 - \lambda(x_1 - x_2)$$


KKT对为 $\mathbf{x}^* = (0, 0)^T, \lambda^* = 1$ . 在 $\lambda^*$ 处,  $L(\mathbf{x}, \lambda^*) = 2x_1^2 - x_2^2$ 为非正定函数. 在 $\lambda^*$ 处的增广Lagrange函数形式:

$$\begin{aligned}\Phi(\mathbf{x}, \lambda^*, \sigma) &= 2x_1^2 - x_2^2 + \frac{1}{2}\sigma(x_1 - x_2)^2 \\ &= \left(2 + \frac{\sigma}{2}\right)x_1^2 - \sigma x_1 x_2 + \left(\frac{\sigma}{2} - 1\right)x_2^2\end{aligned}$$




# 增广拉格朗日函数变化情况


对应不同 $\sigma$ 的增广Lagrange函数 $\Phi(\mathbf{x}, \lambda^*, \sigma)$




(a)  $\sigma=0$



(b)  $\sigma=1$



(c)  $\sigma=4$



(d)  $\sigma=10$

## 增广拉格朗日方法迭代格式

在之前例题中,  $\lambda^*$  是已知的, 实际上  $\lambda^*$  需要通过迭代求出. 下面具体确定迭代格式, 在第  $k$  步迭代, 当  $\sigma_k, \lambda_k$  给定时, 由

$$\min_{\mathbf{x}} \Phi(\mathbf{x}, \lambda_k, \sigma_k)$$

可以得到  $\mathbf{x}_k$ , 并满足  $\nabla_{\mathbf{x}} \Phi(\mathbf{x}_k, \lambda_k, \sigma_k) = 0$ , 即有

$$\nabla f(\mathbf{x}_k) + A(\mathbf{x}_k)[- \lambda_k + \sigma_k c(\mathbf{x}_k)] = 0. \quad (6.4.2)$$

这里:

$$A(\mathbf{x}_k) = [\nabla c_1(\mathbf{x}_k), \cdots, \nabla c_m(\mathbf{x}_k)]$$

# 增广拉格朗日方法

当 $\sigma_k$ 足够大时, 有

$$\nabla f(\mathbf{x}_k) \approx \nabla f(\mathbf{x}^*), \quad A(\mathbf{x}_k) \approx A(\mathbf{x}^*)$$

结合(6.4.2)与KKT条件 $\nabla f(\mathbf{x}^*) - \nabla c(\mathbf{x}^*)\boldsymbol{\lambda}^* = 0$ , 可得到:

$$\boldsymbol{\lambda}^* \approx \boldsymbol{\lambda}_k - \sigma_k \mathbf{c}(\mathbf{x}_k)$$

于是得到求 $\boldsymbol{\lambda}^*$ 的迭代格式:

$$\boldsymbol{\lambda}_{k+1} = \boldsymbol{\lambda}_k - \sigma_k \mathbf{c}(\mathbf{x}_k) \tag{6.4.3}$$

# 增广拉格朗日方法

比较罚函数与增广Lagrange函数的乘子关系，可以分析二者的差别，当 $k$ 充分大时

- 罚函数

$$c_i(\mathbf{x}_k) \approx -\frac{1}{\sigma_k} \lambda_i^*, \quad i \in \mathcal{E} \quad (6.4.4)$$

- 增广Lagrange函数

$$c_i(\mathbf{x}_k) \approx \frac{1}{\sigma_k} (\lambda_i^* - \lambda_i^{(k)}), \quad i \in \mathcal{E} \quad (6.4.5)$$

比较这两个式子可以发现，只要 $\sigma_k$ 充分大， $\lambda_k$ 充分接近 $\lambda^*$ ，乘子罚函数方法得到的 $\mathbf{x}_k$ 比罚函数方法得到的 $\mathbf{x}_k$ 更接近于可行点。

# 增广拉格朗日函数方法步骤

## 算法6.4.1 增广拉格朗日函数方法

步1 给定初始点 $\mathbf{x}_0$ ,  $\boldsymbol{\lambda}_1$ ,  $\sigma_1 > 0$ ,  $\rho > 1$ ,  $\varepsilon > 0$ ,  $\varepsilon_1 > 0$ ,  $k = 1$ .

步2 以 $\mathbf{x}_{k-1}$ 为初始点, 求解:

$$\min_{\mathbf{x}} \Phi(\mathbf{x}, \boldsymbol{\lambda}_k, \sigma_k)$$

得 $\mathbf{x}_k$ , 且满足:

$$\|\nabla_{\mathbf{x}} \Phi(\mathbf{x}_k, \boldsymbol{\lambda}_k, \sigma_k)\| < \varepsilon_1.$$

步3  $\boldsymbol{\lambda}_{k+1} = \boldsymbol{\lambda}_k - \sigma_k \mathbf{c}(\mathbf{x}_k)$ ;

步4 若 $\|\mathbf{c}(\mathbf{x}_k)\| \leq \varepsilon$ , 则停止迭代, 得近似解 $\mathbf{x}_k, \boldsymbol{\lambda}_{k+1}$ ; 否则,  $k := k + 1$ , 取 $\sigma_{k+1} = \rho \sigma_k$ , 转步2.

# 等式约束最优化问题最优解充分条件与必要条件

## 定理 6.4.1 等式约束最优解充分条件与必要条件.

设 $\mathbf{x}^*$ 是等式约束优化问题(6.3.1)的严格局部最优解,  $\boldsymbol{\lambda}^*$ 为对应的最优拉格朗日乘子, 在 $\mathbf{x}^*, \boldsymbol{\lambda}^*$ 处最优性的二阶充分条件满足, 则存在 $\sigma^* \geq 0$ , 对给任何 $\sigma \geq \sigma^*$ ,  $\mathbf{x}^*$ 是增广拉格朗日函数 $\Phi(\mathbf{x}, \boldsymbol{\lambda}^*, \sigma)$ 的严格局部极小点; 反之, 若 $c_i(\mathbf{x}^*) = 0 (i = 1, \dots, m)$ ,  $\mathbf{x}^*$ 是 $\Phi(\mathbf{x}, \boldsymbol{\lambda}^*, \sigma)$ 的局部极小点, 则 $\mathbf{x}^*$ 是等式约束优化问题(6.3.1)的局部极小点。

**证明:** 由 $\Phi(\mathbf{x}, \boldsymbol{\lambda}, \sigma)$ 的定义知:

$$\nabla_{\mathbf{x}} \Phi(\mathbf{x}, \boldsymbol{\lambda}, \sigma) = \nabla_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\lambda}) + \sigma A(\mathbf{x}) \mathbf{c}(\mathbf{x}) \quad (\text{a1})$$

$$\nabla_{\mathbf{x}\mathbf{x}}^2 \Phi(\mathbf{x}, \boldsymbol{\lambda}, \sigma) = \nabla_{\mathbf{x}\mathbf{x}}^2 L(\mathbf{x}, \boldsymbol{\lambda}) + \sigma A(\mathbf{x}) A(\mathbf{x})^T + \sigma \sum_{i \in \mathcal{E}} c_i(\mathbf{x}) \nabla^2 c_i(\mathbf{x}). \quad (\text{a2})$$

## 定理6.4.1证明

**证明续：** 因为 $\mathbf{x}^*$ 为严格局部最优解，由KKT条件与 $\mathbf{x}^*$ 的可行性有：

$$\nabla_{\mathbf{x}}\Phi(\mathbf{x}^*, \boldsymbol{\lambda}^*, \sigma) = \nabla_{\mathbf{x}}L(\mathbf{x}^*, \boldsymbol{\lambda}^*) = 0$$

$$\nabla_{\mathbf{x}\mathbf{x}}^2\Phi(\mathbf{x}^*, \boldsymbol{\lambda}^*, \sigma) = \nabla_{\mathbf{x}\mathbf{x}}^2L(\mathbf{x}^*, \boldsymbol{\lambda}^*) + \sigma A(\mathbf{x}^*)A(\mathbf{x}^*)^T.$$

由约束优化二阶最优性充分条件有：

$$\mathbf{d}^T \nabla_{\mathbf{x}\mathbf{x}}^2L(\mathbf{x}^*, \boldsymbol{\lambda}^*)\mathbf{d} > 0, A(\mathbf{x}^*)^T \mathbf{d} = 0, \mathbf{d} \neq 0.$$

由教材引理7.3(202页)知，存在 $\sigma^* \geq 0$ ，对任意 $\sigma \geq \sigma^*$ ，有 $\nabla_{\mathbf{x}\mathbf{x}}^2L(\mathbf{x}^*, \boldsymbol{\lambda}^*) + \sigma A(\mathbf{x}^*)A(\mathbf{x}^*)^T$ 正定，从而 $\mathbf{x}^*$ 是 $\min \Phi(\mathbf{x}^*, \boldsymbol{\lambda}^*, \sigma)$ 的严格局部最优解。

反之，已知 $\mathbf{x}^*$ 是可行点，设 $\mathbf{x}$ 与 $\mathbf{x}^*$ 充分接近， $\mathbf{x} \in \mathcal{D}$ ，则有：

$$\Phi(\mathbf{x}^*, \boldsymbol{\lambda}^*, \sigma) \leq \Phi(\mathbf{x}, \boldsymbol{\lambda}^*, \sigma)$$

## 定理6.4.1证明

证明续：由 $\boldsymbol{x}^*$ 与 $\boldsymbol{x}$ 的可行性知：

$$\Phi(\boldsymbol{x}^*, \boldsymbol{\lambda}^*, \sigma) = f(\boldsymbol{x}^*), \quad \Phi(\boldsymbol{x}, \boldsymbol{\lambda}^*, \sigma) = f(\boldsymbol{x}).$$

则对与 $\boldsymbol{x}^*$ 充分接近的 $\boldsymbol{x} \in \mathcal{D}$ , 有：

$$f(\boldsymbol{x}^*) \leq f(\boldsymbol{x}),$$

即 $\boldsymbol{x}^*$ 是问题(6.3.1)的局部最优解。 ■



## 例题分析

重新考虑例 6.3.1, 其增广拉格朗日函数为:

$$\Phi(\mathbf{x}, \lambda, \sigma) = f(\mathbf{x}) - \lambda(x_1 - x_2) + \frac{1}{2}\sigma(x_1 - x_2)^2$$

对  $\lambda^* = 1$ , 有:

$$\begin{aligned}\Phi(\mathbf{x}, \lambda^*, \sigma) &= 2x_1^2 - x_2^2 + \frac{1}{2}\sigma(x_1 - x_2)^2, \\ \frac{\partial \Phi}{\partial x_1} &= (4 + \sigma)x_1 - \sigma x_2, \\ \frac{\partial \Phi}{\partial x_2} &= (\sigma - 2)x_2 - \sigma x_1\end{aligned}$$

当  $\sigma > 4$  时,  $\nabla_{\mathbf{x}}^2 \Phi(\mathbf{x}, \lambda^*, \sigma)$  正定, 显然  $\mathbf{x}^* = (0, 0)^T$  是  $\Phi(\mathbf{x}, \lambda^*, \sigma)$  的严格局部极小点.

## 例题分析

反之,  $\Phi(\mathbf{x}, \lambda, \sigma)$  的局部极小点为:

$$x_1 = \frac{1 - \lambda}{\sigma - 4}, \quad x_2 = 2 \frac{1 - \lambda}{\sigma - 4}$$

若要满足约束条件, 只有:

$$\lambda = 1, \text{ 即 } x_1^* = x_2^* = 0$$

是约束优化问题的最优解.

# 一般约束优化问题松弛

引入松弛变量 $\mathbf{s}_i, i \in \mathcal{I}$ , 化一般约束优化问题(6.1.1)为松弛问题:

$$\min F(\mathbf{x}, \mathbf{s}) = f(\mathbf{x}) \quad (6.4.11a)$$

$$\text{s.t. } c_i(\mathbf{x}) = 0, \quad i \in \mathcal{E}, \quad (6.4.11b)$$

$$c_i(\mathbf{x}) - \mathbf{s}_i = 0, \quad i \in \mathcal{I} \quad (6.4.11c)$$

$$\mathbf{s}_i \geq 0, \quad i \in \mathcal{I} \quad (6.4.11d)$$

不考虑松弛变量的非负约束, 则增广拉格朗日函数为:

$$\bar{\Phi}(\mathbf{x}, \mathbf{s}, \boldsymbol{\lambda}, \sigma) = f(\mathbf{x}) - \sum_{i \in \mathcal{E}} \lambda_i c_i(\mathbf{x}) + \frac{1}{2} \sigma \sum_{i \in \mathcal{E}} c_i^2(\mathbf{x}) + \sum_{i \in \mathcal{I}} \bar{\phi}_i \quad (6.4.12)$$

其中

$$\bar{\phi}_i = -\lambda_i(c_i(\mathbf{x}) - s_i) + \frac{1}{2}\sigma(c_i(\mathbf{x}) - s_i)^2$$

# 增广拉格朗日函数方法

带松弛变量非负约束的增广拉格朗日函数最优化问题为：

$$\begin{aligned} \min_{\mathbf{x}, \mathbf{s}} \quad & \bar{\Phi}(\mathbf{x}, \mathbf{s}, \boldsymbol{\lambda}, \sigma), \\ \text{s.t.} \quad & s_i \geq 0, i \in \mathcal{I}. \end{aligned} \tag{6.4.13}$$

以上问题增加了  $m - m'$  个变量，需要将该问题化简，消去所有松弛变量。考虑等价问题：

$$\begin{aligned} \min_{\mathbf{x}} \min_{\mathbf{s}} \quad & \bar{\Phi}(\mathbf{x}, \mathbf{s}, \boldsymbol{\lambda}, \sigma), \\ \text{s.t.} \quad & s_i \geq 0, i \in \mathcal{I}. \end{aligned} \tag{6.4.14}$$

通过求解以下问题：

$$\begin{aligned} \min_{\mathbf{s}} \quad & \bar{\Phi}(\mathbf{x}, \mathbf{s}, \boldsymbol{\lambda}, \sigma), \\ \text{s.t.} \quad & s_i \geq 0, i \in \mathcal{I}. \end{aligned} \tag{6.4.15}$$

得到  $\mathbf{s}(\mathbf{x})$  的解析表达式。

# 增广拉格朗日函数方法

将 $s(x)$ 代入 $\bar{\Phi}$ , 就可以消去 $s$ , 使得:

$$\Phi(x, \lambda, \sigma) = \bar{\Phi}(x, s(x), \lambda, \sigma)$$

易验证, 在问题(6.4.15)中,  $\bar{\Phi}(x, s, \lambda, \sigma)$ 是关于 $s$ 的凸函数.  $\bar{\Phi}$ 关于 $s$ 的稳定点即为极小点, 所以由 $\nabla_s \bar{\Phi}(x, s, \lambda, \sigma) = 0$ , 即:

$$\frac{\partial \bar{\phi}_i}{\partial s_i} = \lambda_i - \sigma c_i(x) + \sigma s_i = 0, \quad i \in \mathcal{I}$$

由此解出 $s$ , 即:

$$s_i = c_i(x) - \eta_i, \quad i \in \mathcal{I}$$

其中 $\eta_i = \lambda_i / \sigma$ 。

# 增广拉格朗日函数方法

考虑 $s_i$ 的非负约束，问题(6.4.15)的解析表达式为：

$$s_i = \max\{c_i(x) - \eta_i, 0\}, \quad i \in \mathcal{I} \quad (6.4.16)$$

令 $\phi_i(\mathbf{x}, \boldsymbol{\lambda}, \sigma) = \bar{\phi}_i(\mathbf{x}, \mathbf{s}(\mathbf{x}), \boldsymbol{\lambda}, \sigma)$ ，则有：

$$\phi_i = \begin{cases} -\frac{1}{2}\sigma\eta_i^2 & c_i(\mathbf{x}) - \eta_i \geq 0 \\ \frac{1}{2}\sigma [(c_i(\mathbf{x}) - \eta_i)^2 - \eta_i^2] & c_i(\mathbf{x}) - \eta_i < 0 \end{cases} \quad (6.4.17)$$

由此得到化简后的增广拉格朗日函数：

$$\Phi(\mathbf{x}, \boldsymbol{\lambda}, \sigma) = f(\mathbf{x}) - \sum_{i \in \mathcal{E}} \lambda_i c_i(\mathbf{x}) + \frac{1}{2}\sigma \sum_{i \in \mathcal{E}} c_i^2(\mathbf{x}) + \sum_{i \in \mathcal{I}} \phi_i(\mathbf{x}, \boldsymbol{\lambda}, \sigma) \quad (6.4.18)$$

# 增广拉格朗日函数方法乘子迭代格式

假定第 $k$ 步迭代已知 $\mathbf{x}_k, \boldsymbol{\lambda}_k, \sigma_k$ , 求 $\boldsymbol{\lambda}_{k+1}$ 的迭代格式如下:

$$\begin{aligned}\lambda_i^{(k+1)} &= \lambda_i^{(k)} - \sigma_k c_i(\mathbf{x}_k), & i \in \mathcal{E} \\ \lambda_i^{(k+1)} &= \lambda_i^{(k)} - \sigma_k [c_i(\mathbf{x}_k) - s_i^{(k)}], & i \in \mathcal{I}\end{aligned}$$

进一步化简后, 有:

$$\lambda_i^{(k+1)} = -\sigma_k \min \left\{ (c_i(\mathbf{x}_k) - \eta_i^{(k)}, 0) \right\} \quad (6.4.19)$$

这里 $\eta_i^{(k)} = \frac{\lambda_i^{(k)}}{\sigma_k}$ .

# 增广拉格朗日函数方法乘子终止准则

由等式约束最优化终止准则：

$$\left[ \sum_{i \in \mathcal{E}} c_i^2(\mathbf{x}_k) + \sum_{i \in \mathcal{I}} \left( c_i(\mathbf{x}_k) - s_i^{(k)} \right)^2 \right]^{1/2} \leq \epsilon \quad (6.4.20)$$

简化后有：

$$\left[ \sum_{i \in \mathcal{E}} c_i^2(\mathbf{x}_k) + \sum_{i \in \mathcal{I}} \min \left\{ c_i(\mathbf{x}_k), \eta_i^{(k)} \right\}^2 \right]^{1/2} \leq \epsilon \quad (6.4.21)$$



# 数值实验

考虑以下三个约束优化问题：

问题 1

$$\begin{aligned}\min f(x) &= -1, \\ \text{s.t. } x_1^2 + x_2^2 - 25 &= 0, \\ x_1 x_2 - 9 &= 0.\end{aligned}$$

问题 2

$$\begin{aligned}\min f(x) &= -x_1, \\ \text{s.t. } x_2 - x_1^3 - x_3^2 &= 0, \\ x_1^2 - x_2 - x_4^2 &= 0.\end{aligned}$$

问题 3

$$\begin{aligned}\min f(x) &= \frac{1}{2}x_1^2 + x_2^2 - x_1 x_2 - 7x_1 - 7x_2, \\ \text{s.t. } 25 - 4x_1^2 - x_2^2 &\geq 0.\end{aligned}$$

无约束优化算法：BFGS方法与非精确强Wolfe线性搜索，终止准则 $|f_{k-1} - f_k| \leq 10^{-8}$

# 数值实验

问题	方法	ite	feva	$\mu_k$	$\ x^{(k)} - x^*\ _\infty$
问题 1	外点罚函数方法	4	76	$1.0e - 03$	$2.7076e - 01$
	增广 Lagrange 函数方法	5	68	$1.0e - 04$	$2.7076e - 01$
问题 2	外点罚函数方法	10	137	$1.0e - 10$	$1.1502e - 08$
	增广 Lagrange 函数方法	6	93	$1.0e - 06$	$4.8881e - 12$
问题 3	障碍函数方法	9	178	$1.0e - 09$	$3.9048e - 06$
	增广 Lagrange 函数方法	4	274	$1.0e - 04$	$9.4892e - 06$

总体来讲，增广拉格朗日方法需要较少的外层迭代次数，与罚函数法相比，需要更少的函数值计算次数。